ACH2036 - Métodos Quantitativos para Análise Multivariada

Atividade 1 - Modelos de Regressão: Análise de resíduos e transformações de escala

Versão do enunciado: 05/10

Atualizações desta versão em relação à anterior:

a) Especificação exata das localizações dos datasets *Treadwear* e *Alligators* dentro do curso STAT501;

b) Inserção de algumas figuras adicionais de exemplos

c) Revisão da Seção 3. Etapas da análise

d) Orientações adicionais para entrega do trabalho.

1 Objetivo

O objetivo desta atividade é:

- Consolidar alguns dos conceitos e técnicas sobre Regressão Linear Simples apresentados nas Seções 1, 2, 3 e 4 do material didático STAT501 - Regression Methods (https://online.stat.psu.edu/stat501/);
- Exercitar a análise exploratória de dados;
- Exercitar o diagnóstico do ajuste da regressão através da análise de resíduos;
- Explorar o uso de transformações de escalas nas variáveis para a obtenção de melhores ajustes da regressão.

2 *Datasets* a serem analisados

1. **Treadwear**:
   - Os detalhes do problema e o dataset encontram-se na Subseção *4.4 - Identifying Specific Problems Using Residual Plots* de STAT501 Clique em: *How does a non-linear regression function show up on a residual vs. fits plot?*
   - Variável resposta (Y): `groove`
   - Variável preditora (X): `mileage`
2. **Alligators**:
   - Os detalhes do problema e o dataset encontram-se na Subseção *4.7 - Assessing Linearity by Visual Inspection*
   - Variável resposta (Y): `weight`
   - Variável preditora (X): `length`

3. **ConcPatog.txt**:

   - Disponível no subdiretório *datasets* do Drive compartilhado ACH2036_2026.
   - Este dataset contém as concentrações de dois protozoários em água de esgoto tratado. Essas concentrações foram medidas sob diferentes estações de tratamento, estágios de tratamento e meses do ano.
   - O interesse é saber se é possível ajustar um modelo de regressão que permita estimar, com razoável acurácia, a concentração do patógeno 2 a partir da concentração do patógeno 1.
   - Variável resposta (Y): `CPatog2`
   - Variável preditora (X): `CPatog1`

3 Etapas da análise:

Para cada um dos *datasets*, você deverá realizar as seguintes etapas:

3.1 Análise de regressão preliminar sobre o dataset original

Esta etapa consiste em fazer uma breve análise de regressão com o dataset original, sem transformações de escala.

1. Plotar um gráfico de dispersão entre a variável resposta (eixo vertical) e a variável preditora (eixo horizontal).

   Comente sobre o gráfico: existe indício visual de associação linear entre as variáveis? Se não, que fenômenos você observa em termos da tendência, concentrações dos pontos, dispersão, etc.

2. Ajustar um modelo de regressão linear simples entre a variável preditora e a variável resposta, exibindo os seguintes resultados:

   - Tabela geral dos resultados do ajuste, conforme exemplo apresentado no Notebook SLR_Hospital_Infection.ipynb (ver figura abaixo).

OLS Regression Results

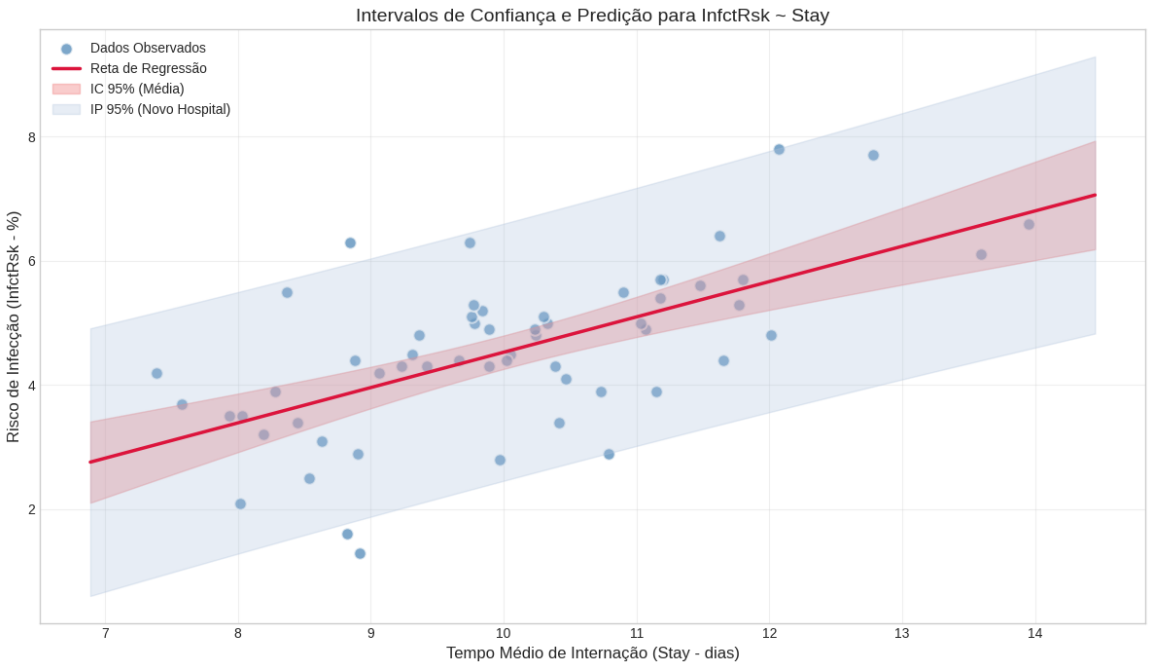
Dep. Variable:	InfctRsk	R-squared:	0.395
Model:	OLS	Adj. R-squared:	0.384
Method:	Least Squares	F-statistic:	36.50
Date:	Fri, 25 Sep 2026	Prob (F-statistic):	1.30e-07
Time:	20:45:26	Log-Likelihood:	-82.684
No. Observations:	58	AIC:	169.4
Df Residuals:	56	BIC:	173.5
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-1.1598	0.956	-1.213	0.230	-3.075	0.755
Stay	0.5689	0.094	6.041	0.000	0.380	0.757

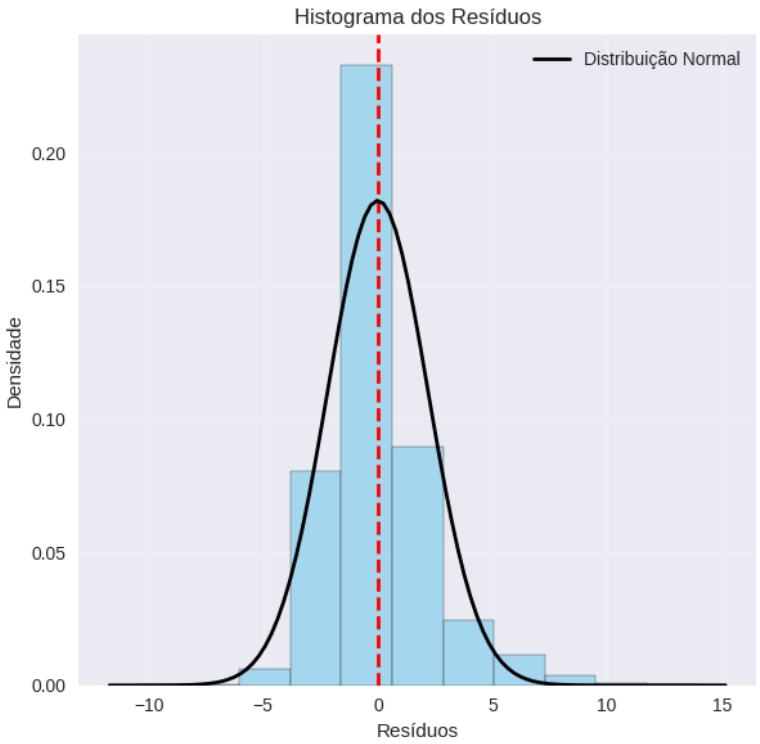
Omnibus:	1.579	Durbin-Watson:	2.075
Prob(Omnibus):	0.454	Jarque-Bera (JB):	0.839
Skew:	-0.170	Prob(JB):	0.657
Kurtosis:	3.481	Cond. No.	72.8

Comentar o valor do R^2 ajustado. Com base neste indicador, é possível afirmar que o modelo captura bem a variabilidade da variável resposta?

- Gráfico de dispersão incluindo a reta da regressão, intervalo de confiança e intervalo de predição. Você pode aproveitar o código do Notebook citado acima. Exemplo:

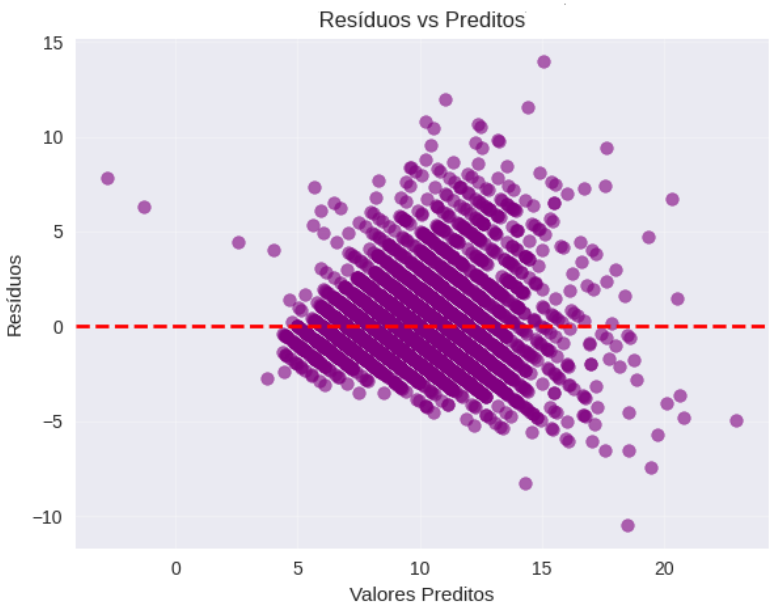


- Apresente os seguintes gráficos dos resíduos:
  - Histograma dos resíduos (com a respectiva densidade sob a distribuição normal, se possível). Exemplo:



Atenção: Não será possível plotar este histograma para o dataset Treadwear, devido ao baixo tamanho da amostra.

– Gráfico dos resíduo vs. valores preditos. Exemplo:



– QQ-plot dos resíduos usando a distribuição normal como referência. Exemplo:



3. Com base nesses gráficos, as premissas **LINE** (**L**inear function, **I**ndependent errors, **N**ormal distribution, **E**qual variance) são satisfeitas? Comente quais dessas premissas parecem válidas e quais parecem violadas.

3.2 Exploração das diferentes possibilidades de transformações de escala

Agora, você deverá testar diferentes combinações de transformações sobre as variáveis, analisar os gráficos de dispersão dos dados e escolher a combinação de transformações que pareça produzir um modelo que atenda (ainda que parcialmente) as premisas **LINE**.

1. Teste diferentes transformações sobre X ou sobre Y:
   - Raiz quadrada (somente sobre X, somente sobre Y ou sobre ambas)
   - Quadrado (somente sobre X, somente sobre Y ou sobre ambas)
   - Logaritmo na base 10 (somente sobre X, somente sobre Y ou sobre ambas). Embora o logaritmo natural seja bastante utilizado, eu tendo a preferir o log10 por ser mais fácil de interpretar
2. Para cada uma dessas nove possibilidades, plote um gráfico de dispersão sobre as variáveis transformadas e verifique se há uma associação entre as variáveis.
   Não é necessário incluir cada um desses gráficos no relatório. Eles servirão apenas para sua análise.
3. Escolha a combinação de transformações cujo gráfico de dispersão indique a melhor associação linear entre a variável resposta e a variável preditora (com suas respectivas transformações).

3.3 Análise da combinação escolhida

- Após escolher a combinação de transformações apropriada, você deve informar qual é.
- Apresente todos os resultados solicitados na Etapa 3.1 acima (mas sobre os dados com as transformações de escala otimizadas).

4 Formato e prazo para entrega

- Deverá ser entregue um relatório em formato PDF. Não incluir seus códigos Python.
- O relatório pode ser feito individualmente ou em duplas (não necessariamente da mesma turma).
- Na 1a página do relatório, deverão ser informados os Números USP e os nomes completos dos dois membros.
- A entrega deverá ser feita exclusivamente através do e-disciplinas. Se o trabalho for em grupo, *apenas um aluno deverá submetê-lo no e-disciplinas*
- **Prazo para entrega: 13/10**