Universidade de São Paulo
ACH2036 - Métodos Quantitativos para Análise Multivariada
Prof. Doutor: Marcelo de Souza Lauretto **Ano:** 2° Semestre/2026

Atividade 1 - Modelos de Regressão: Análise de resíduos e transformações de escala

Kauã Lima de Souza
15674702

Victor Yodono
13829040

I. Introdução

Este relatório apresenta a análise de regressão linear simples sobre três conjuntos de dados (Treadwear, Alligators e ConcPatog), conforme proposto na Atividade 1 da disciplina. Para cada conjunto, ajustamos inicialmente o modelo sobre os dados originais e fizemos o diagnóstico do ajuste por meio da análise de resíduos, verificando as premissas LINE (função **L**inear, erros **I**ndependentes, distribuição **N**ormal e variância **E**gual). Em seguida, exploramos nove combinações de transformações de escala (raiz quadrada, quadrado e logaritmo na base 10, aplicados somente sobre X, somente sobre Y ou sobre ambas) e repetimos a análise sob a combinação que produziu a melhor associação linear. Os conceitos e técnicas utilizados seguem as Seções 1 a 4 do material STAT501 [1].

II. Dataset Treadwear

A. *Análise preliminar sobre os dados originais*

1. *Gráfico de dispersão*

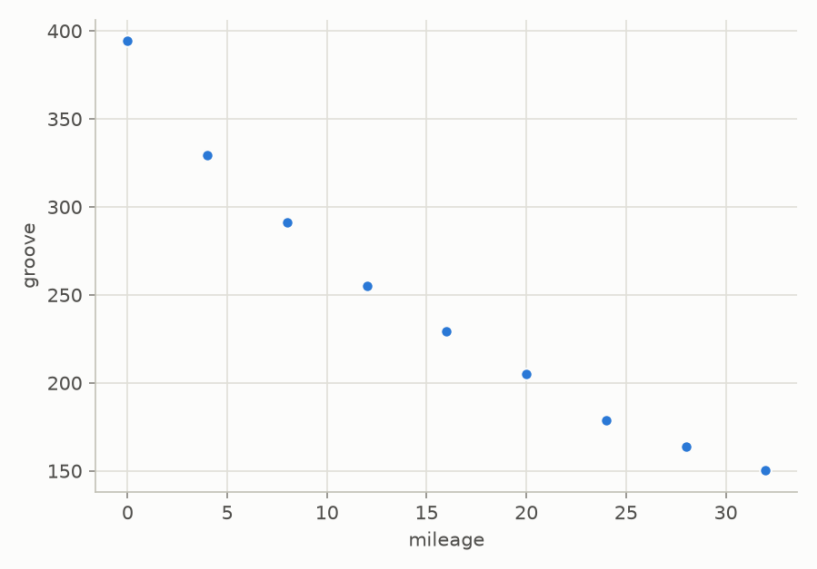


Figura I: Dispersão entre groove e mileage (dados originais).

O gráfico mostra uma associação negativa forte, que à primeira vista parece linear, com a profundidade do groove diminuindo conforme a quilometragem em milhas aumenta e pouca dispersão em torno da tendência. Olhando de perto, a tendência é ser uma curva, pois o groove cai cerca de 65 mils nas primeiras 4 mil milhas e só cerca de 13 a 15 nas últimas, então uma reta passaria abaixo dos pontos nos extremos e acima no meio, o que indica que a relação não é exatamente linear.

2. Ajuste do modelo

../outputs/treadwear/original_ols.txt

Tabela I: Resultados do ajuste por mínimos quadrados (dados originais).

[Comentar o R^2 ajustado: com base nele, o modelo captura bem a variabilidade da variável resposta?]

../outputs/treadwear/original_icip.png

Figura II: Reta de regressão com intervalos de confiança e de predição de 95% (dados originais).

3. Análise dos resíduos

O histograma dos resíduos não foi incluído para este *dataset*, pois o tamanho reduzido da amostra não permite uma representação informativa da distribuição.

../outputs/treadwear/original_residuos_preditos.png

Figura III: Resíduos vs. valores preditos (dados originais).

../outputs/treadwear/original_qqplot.png

Figura IV: QQ-plot dos resíduos contra a distribuição normal (dados originais).

4. Premissas LINE

[Com base nos gráficos, indicar quais premissas parecem válidas e quais parecem violadas.]

B. Exploração das transformações de escala

Para cada uma das nove combinações de transformações, avaliamos o gráfico de dispersão das variáveis transformadas. A Tabela II resume essa avaliação.

Transformação	**Aplicada em**	R^2 **ajustado**	**Associação linear (avaliação visual)**
Raiz quadrada	X	*[?]*	*[?]*
Raiz quadrada	Y	*[?]*	*[?]*
Raiz quadrada	X e Y	*[?]*	*[?]*
Quadrado	X	*[?]*	*[?]*
Quadrado	Y	*[?]*	*[?]*
Quadrado	X e Y	*[?]*	*[?]*
$\log_{10}$	X	*[?]*	*[?]*
$\log_{10}$	Y	*[?]*	*[?]*
$\log_{10}$	X e Y	*[?]*	*[?]*

Tabela II: Combinações de transformações testadas no dataset Treadwear.

[Justificar a escolha da combinação com melhor associação linear.]

C. Análise da combinação escolhida

A combinação de transformações escolhida foi *[transformação sobre X e/ou Y]*.

1. Gráfico de dispersão

../outputs/treadwear/transformado_dispersao.png

Figura V: Dispersão entre as variáveis transformadas.

[Comentar a associação linear após a transformação.]

2. Ajuste do modelo

../outputs/treadwear/transformado_ols.txt

Tabela III: Resultados do ajuste por mínimos quadrados (dados transformados).

[Comentar o R^2 ajustado e compará-lo ao do modelo original.]



Figura VI: Reta de regressão com intervalos de confiança e de predição de 95% (dados transformados).

3. Análise dos resíduos

Assim como na análise preliminar, o histograma dos resíduos não foi incluído devido ao tamanho reduzido da amostra.



Figura VII: Resíduos vs. valores preditos (dados transformados).

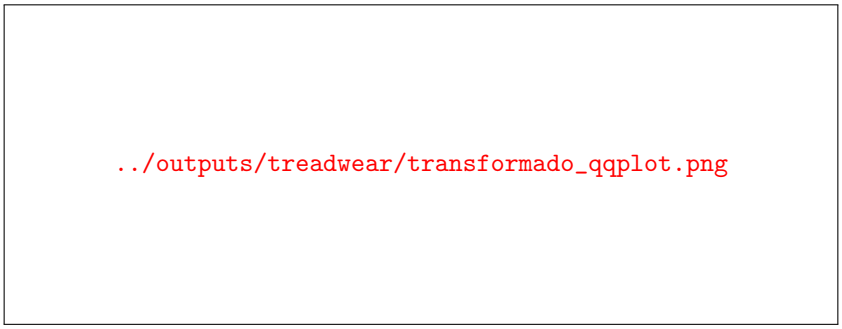


Figura VIII: QQ-plot dos resíduos contra a distribuição normal (dados transformados).

4. Premissas LINE

[Indicar quais premissas passaram a ser atendidas, ainda que parcialmente, e quais continuam violadas.]

III. Dataset Alligators

O *dataset* Alligators, apresentado na Subseção 4.7 do STAT501 [1], relaciona o peso de jacarés (`weight`, variável resposta Y) com o seu comprimento (`length`, variável preditora X).

A. Análise preliminar sobre os dados originais

1. Gráfico de dispersão

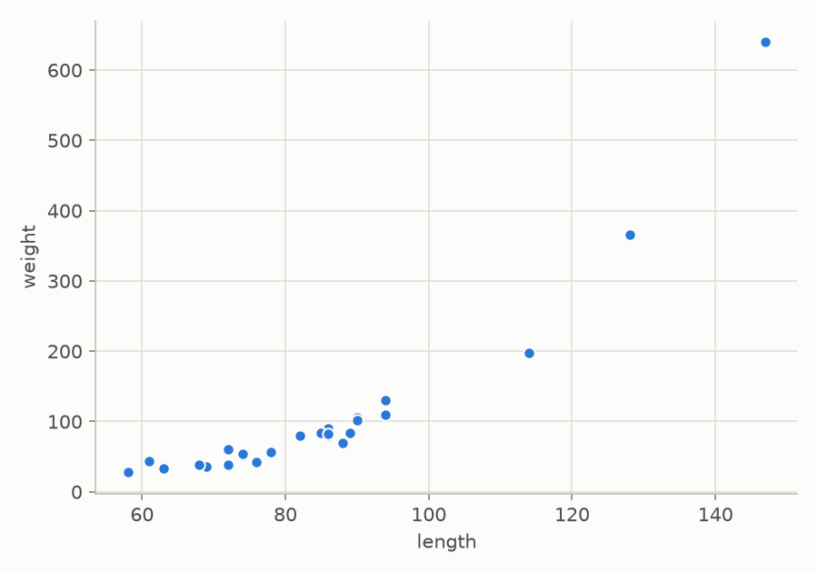


Figura IX: Dispersão entre weight e length (dados originais).

O gráfico mostra uma associação positiva, mas não linear, com o weight crescendo cada vez mais rápido conforme o length aumenta, num formato parecido com uma exponencial. Entre 58 e 94 de length o weight sobe cerca de 3 por unidade, e entre 94 e 147 sobe cerca de 10. Os pontos se concentram nessa primeira faixa, com 22 dos 25 jacarés e pouca dispersão, e só 3 jacarés grandes e pesados ficam isolados à direita, deixando a curva evidente.

2. Ajuste do modelo

../outputs/alligators/original_ols.txt

Tabela IV: Resultados do ajuste por mínimos quadrados (dados originais).

[Comentar o R^2 ajustado: com base nele, o modelo captura bem a variabilidade da variável resposta?]

../outputs/alligators/original_icip.png

Figura X: Reta de regressão com intervalos de confiança e de predição de 95% (dados originais).

3. Análise dos resíduos



Figura XI: Histograma dos resíduos com a densidade normal de referência (dados originais).



Figura XII: Resíduos vs. valores preditos (dados originais).



Figura XIII: QQ-plot dos resíduos contra a distribuição normal (dados originais).

4. Premissas LINE

[Com base nos gráficos, indicar quais premissas parecem válidas e quais parecem violadas.]

B. Exploração das transformações de escala

Para cada uma das nove combinações de transformações, avaliamos o gráfico de dispersão das variáveis transformadas. A Tabela V resume essa avaliação.

Transformação	**Aplicada em**	R^2 **ajustado**	**Associação linear (avaliação visual)**
Raiz quadrada	X	*[?]*	*[?]*
Raiz quadrada	Y	*[?]*	*[?]*
Raiz quadrada	X e Y	*[?]*	*[?]*
Quadrado	X	*[?]*	*[?]*
Quadrado	Y	*[?]*	*[?]*
Quadrado	X e Y	*[?]*	*[?]*
$\log_{10}$	X	*[?]*	*[?]*
$\log_{10}$	Y	*[?]*	*[?]*
$\log_{10}$	X e Y	*[?]*	*[?]*

Tabela V: Combinações de transformações testadas no dataset Alligators.

[Justificar a escolha da combinação com melhor associação linear.]

C. Análise da combinação escolhida

A combinação de transformações escolhida foi *[transformação sobre X e/ou Y]*.

1. Gráfico de dispersão

../outputs/alligators/transformado_dispersao.png

Figura XIV: Dispersão entre as variáveis transformadas.

[Comentar a associação linear após a transformação.]

2. Ajuste do modelo

../outputs/alligators/transformado_ols.txt

Tabela VI: Resultados do ajuste por mínimos quadrados (dados transformados).

[Comentar o R^2 ajustado e compará-lo ao do modelo original.]

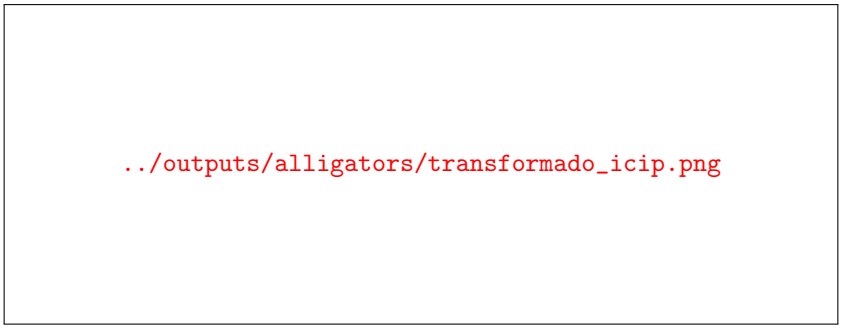


Figura XV: Reta de regressão com intervalos de confiança e de predição de 95% (dados transformados).

3. Análise dos resíduos

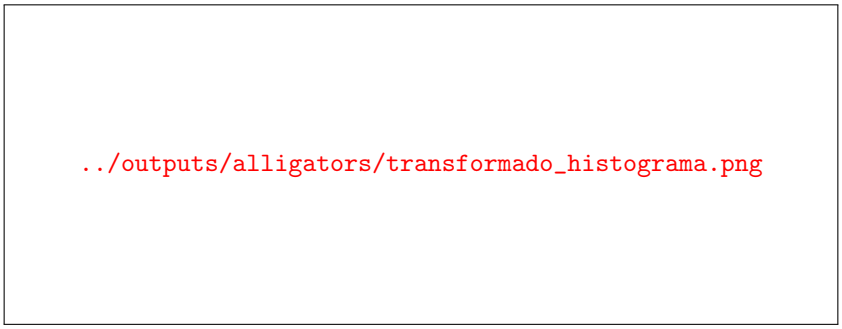


Figura XVI: Histograma dos resíduos com a densidade normal de referência (dados transformados).

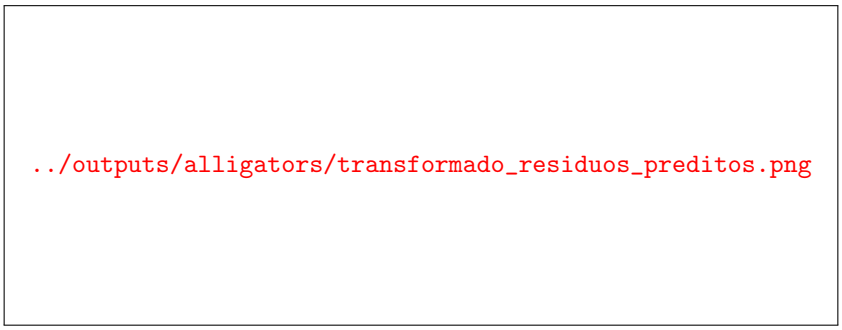


Figura XVII: Resíduos vs. valores preditos (dados transformados).

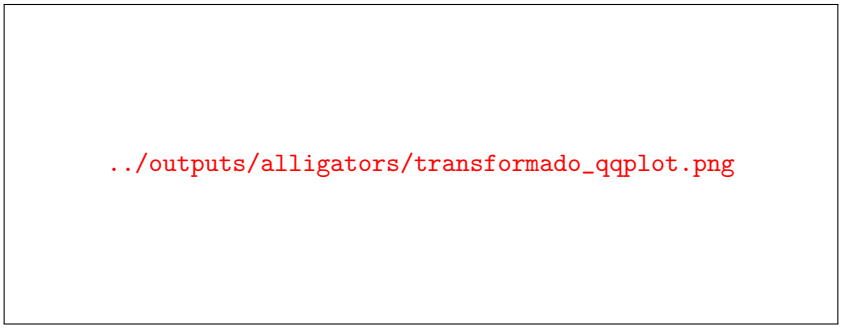


Figura XVIII: QQ-plot dos resíduos contra a distribuição normal (dados transformados).

4. Premissas LINE

[Indicar quais premissas passaram a ser atendidas, ainda que parcialmente, e quais continuam violadas.]

IV. Dataset ConcPatog

O *dataset* ConcPatog contém as concentrações de dois protozoários em água de esgoto tratado, medidas sob diferentes estações de tratamento, estágios de tratamento e meses do ano. O interesse é verificar se é possível estimar, com razoável acurácia, a concentração do patógeno 2 (`CPatog2`, variável resposta Y) a partir da concentração do patógeno 1 (`CPatog1`, variável preditora X).

A. Análise preliminar sobre os dados originais

1. Gráfico de dispersão

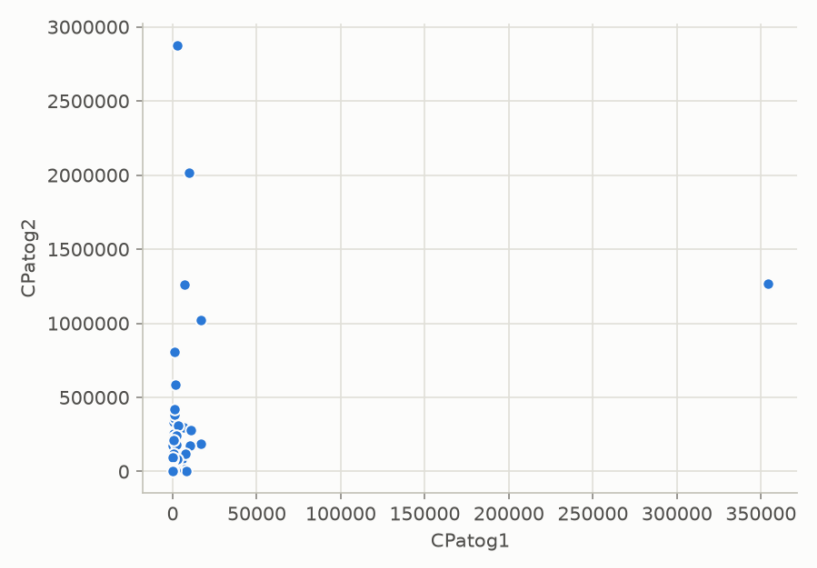


Figura XIX: Dispersão entre CPatog2 e CPatog1 (dados originais).

No gráfico original não há indício visual de associação linear, porque quase todos os pontos ficam espremidos perto da origem, com 104 dos 105 valores de CPatog1 abaixo de 17 mil e 98 dos valores de CPatog2 abaixo de 500 mil. Dentro desse aglomerado a dispersão de CPatog2 é muito grande, e alguns pontos extremos dominam o gráfico, como um único CPatog1 perto de 354 mil e quatro valores de CPatog2 acima de 1 milhão com CPatog1 baixo. As duas variáveis variam em várias ordens de grandeza, com CPatog1 indo de 0 a 354 mil (mediana 359) e CPatog2 de 4 a quase 3 milhões (mediana 13.900), e supomos que isso comprime os pontos e impede de enxergar uma tendência na escala original.

2. Ajuste do modelo

`../outputs/concpatog/original_ols.txt`

Tabela VII: Resultados do ajuste por mínimos quadrados (dados originais).

[Comentar o R^2 ajustado: com base nele, o modelo captura bem a variabilidade da variável resposta?]



Figura XX: Reta de regressão com intervalos de confiança e de predição de 95% (dados originais).

3. Análise dos resíduos



Figura XXI: Histograma dos resíduos com a densidade normal de referência (dados originais).



Figura XXII: Resíduos vs. valores preditos (dados originais).



Figura XXIII: QQ-plot dos resíduos contra a distribuição normal (dados originais).

4. Premissas LINE

[Com base nos gráficos, indicar quais premissas parecem válidas e quais parecem violadas.]

B. Exploração das transformações de escala

Para cada uma das nove combinações de transformações, avaliamos o gráfico de dispersão das variáveis transformadas. A Tabela VIII resume essa avaliação.

Transformação	**Aplicada em**	R^2 **ajustado**	**Associação linear (avaliação visual)**
Raiz quadrada	X	*[?]*	*[?]*
Raiz quadrada	Y	*[?]*	*[?]*
Raiz quadrada	X e Y	*[?]*	*[?]*
Quadrado	X	*[?]*	*[?]*
Quadrado	Y	*[?]*	*[?]*
Quadrado	X e Y	*[?]*	*[?]*
$\log_{10}$	X	*[?]*	*[?]*
$\log_{10}$	Y	*[?]*	*[?]*
$\log_{10}$	X e Y	*[?]*	*[?]*

Tabela VIII: Combinações de transformações testadas no dataset ConcPatog.

[Justificar a escolha da combinação com melhor associação linear.]

C. Análise da combinação escolhida

A combinação de transformações escolhida foi *[transformação sobre X e/ou Y]*.

1. Gráfico de dispersão

../outputs/concpatog/transformado_dispersao.png

Figura XXIV: Dispersão entre as variáveis transformadas.

[Comentar a associação linear após a transformação.]

2. Ajuste do modelo

../outputs/concpatog/transformado_ols.txt

Tabela IX: Resultados do ajuste por mínimos quadrados (dados transformados).

[Comentar o R^2 ajustado e compará-lo ao do modelo original. O modelo permite estimar CPatog2 com razoável acurácia?]



Figura XXV: Reta de regressão com intervalos de confiança e de predição de 95% (dados transformados).

3. Análise dos resíduos



Figura XXVI: Histograma dos resíduos com a densidade normal de referência (dados transformados).



Figura XXVII: Resíduos vs. valores preditos (dados transformados).

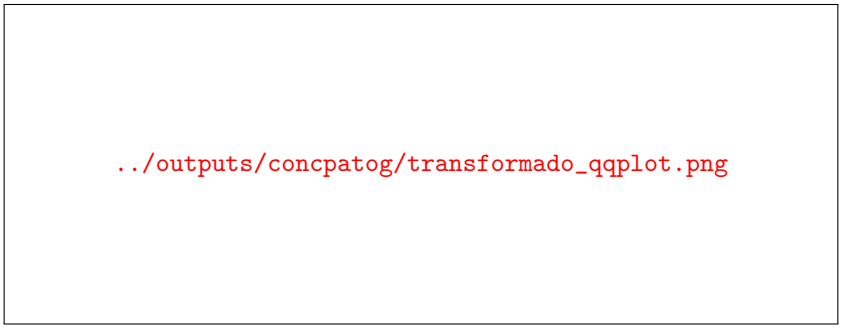


Figura XXVIII: QQ-plot dos resíduos contra a distribuição normal (dados transformados).

4. Premissas LINE

[Indicar quais premissas passaram a ser atendidas, ainda que parcialmente, e quais continuam violadas.]

Referências

[1] THE PENNSYLVANIA STATE UNIVERSITY. **STAT 501: Regression Methods**. University Park: Eberly College of Science. Disponível em: `https://online.stat.psu.edu/stat501/`. Acesso em: 11 out. 2026.