Universidade de São Paulo
ACH2036 - Métodos Quantitativos para Análise Multivariada
Prof. Doutor: Marcelo de Souza Lauretto **Ano:** 2° Semestre/2026

Atividade 1 - Modelos de Regressão: Análise de resíduos e transformações de escala

Kauã Lima de Souza
15674702

Victor Yodono
13829040

I. Introdução

Este relatório apresenta a análise de regressão linear simples sobre três conjuntos de dados (Treadwear, Alligators e ConcPatog), conforme proposto na Atividade 1 da disciplina. Para cada conjunto, ajustamos inicialmente o modelo sobre os dados originais e fizemos o diagnóstico do ajuste por meio da análise de resíduos, verificando as premissas LINE (função **L**inear, erros **I**ndependentes, distribuição **N**ormal e variância **E**gual). Em seguida, exploramos nove combinações de transformações de escala (raiz quadrada, quadrado e logaritmo na base 10, aplicados somente sobre X, somente sobre Y ou sobre ambas) e repetimos a análise sob a combinação que produziu a melhor associação linear. Os conceitos e técnicas utilizados seguem as Seções 1 a 4 do material STAT501 [1].

II. Dataset Treadwear

O *dataset* Treadwear, apresentado na Subseção 4.4 do STAT501 [1], vem de um experimento de laboratório que relaciona a profundidade restante do sulco de um pneu (`groove`, em mils, variável resposta Y) com a quilometragem rodada (`mileage`, em milhares de milhas, variável preditora X).

A. Análise preliminar sobre os dados originais

1. Gráfico de dispersão

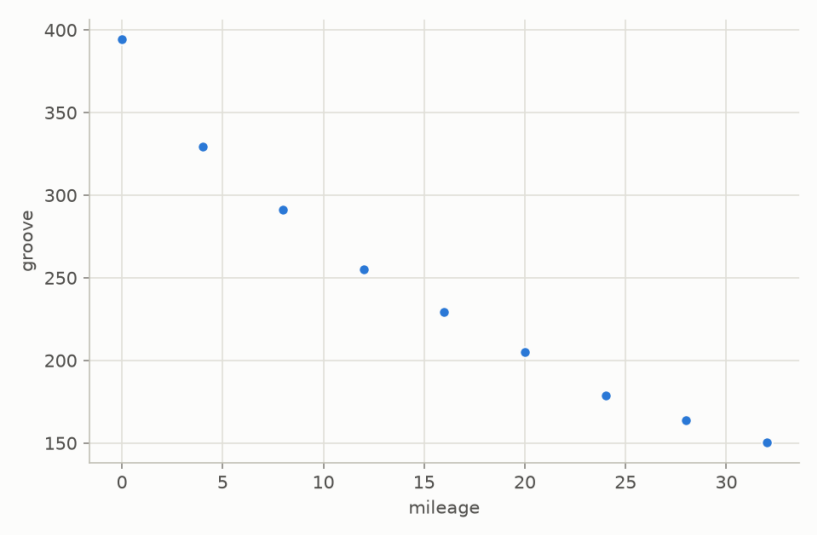


Figura I: Dispersão entre groove e mileage (dados originais).

O gráfico mostra uma associação negativa forte, que à primeira vista parece linear, com a profundidade do groove diminuindo conforme a quilometragem em milhas aumenta e pouca dispersão em torno da tendência. Olhando de perto, a tendência é ser uma curva, pois o groove cai cerca de 65 mils nas primeiras 4 mil milhas e só cerca de 13 a 15 nas últimas, então uma reta passaria abaixo dos pontos nos extremos e acima no meio, o que indica que a relação não é exatamente linear.

2. Ajuste do modelo

OLS Regression Results

Dep. Variable:	groove	R-squared:	0.953
Model:	OLS	Adj. R-squared:	0.946
Method:	Least Squares	F-statistic:	140.7
		Prob (F-statistic):	6.87e-06
		Log-Likelihood:	-38.148
No. Observations:	9	AIC:	80.30
Df Residuals:	7	BIC:	80.69
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	360.6367	11.689	30.854	0.000	332.998	388.276
mileage	-7.2806	0.614	-11.862	0.000	-8.732	-5.829

Omnibus:	2.406	Durbin-Watson:	0.746
Prob(Omnibus):	0.300	Jarque-Bera (JB):	1.330
Skew:	0.900	Prob(JB):	0.514
Kurtosis:	2.445	Cond. No.	35.2

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Tabela I: Resultados do ajuste por mínimos quadrados (dados originais).

O R^2 ajustado é de 0,946, então a reta explica cerca de 95% da variação do groove, e a inclinação de $-7{,}28$ indica que o groove perde em média uns 7,3 mils a cada mil milhas rodadas. Olhando só para o R^2 o modelo parece capturar muito bem a variabilidade da resposta, mas o próprio STAT501 usa esse *dataset* para mostrar uma relação que não é linear, e um R^2 alto não garante que a reta seja a forma certa da relação. No gráfico com os intervalos os pontos das pontas ficam acima da reta e os do meio abaixo dela, a mesma curva que já tínhamos visto na dispersão, mas todas as 9 medições caem dentro do intervalo de predição.

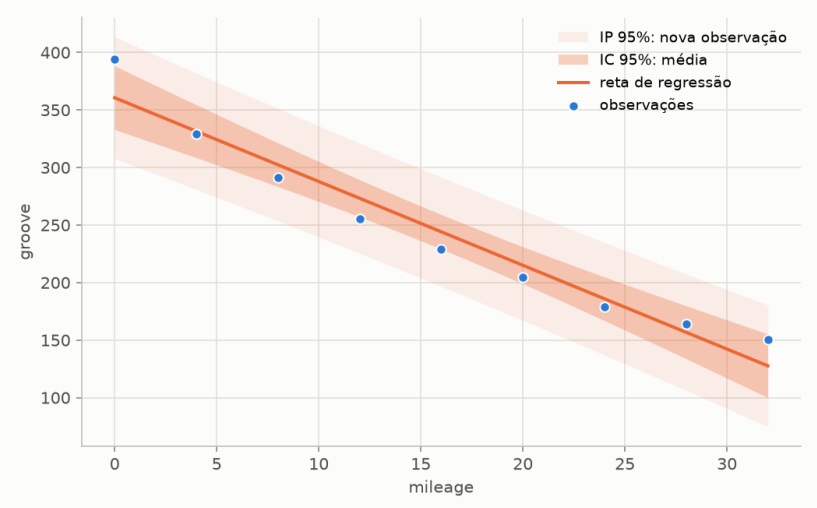


Figura II: Reta de regressão com intervalos de confiança e de predição de 95% (dados originais).

3. Análise dos resíduos

Deixamos o histograma dos resíduos de fora, como o enunciado orienta, porque com só 9 observações ele quase não mostra a forma da distribuição.

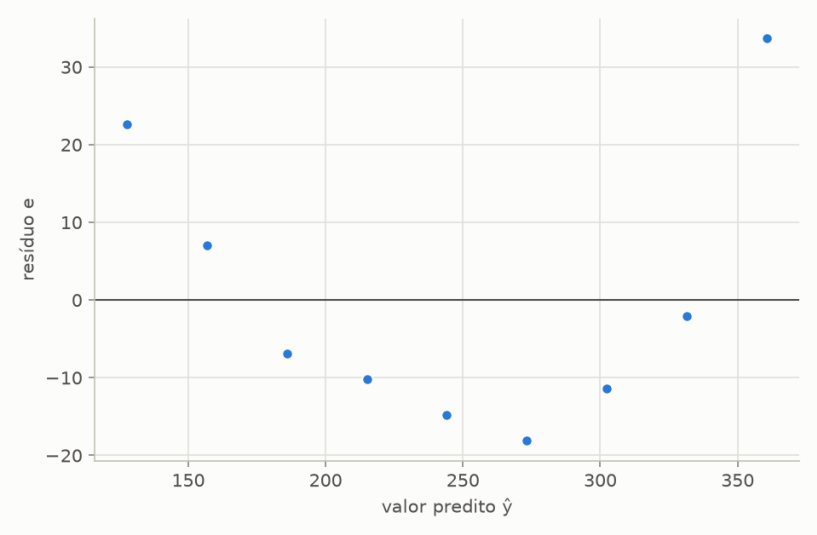


Figura III: Resíduos vs. valores preditos (dados originais).

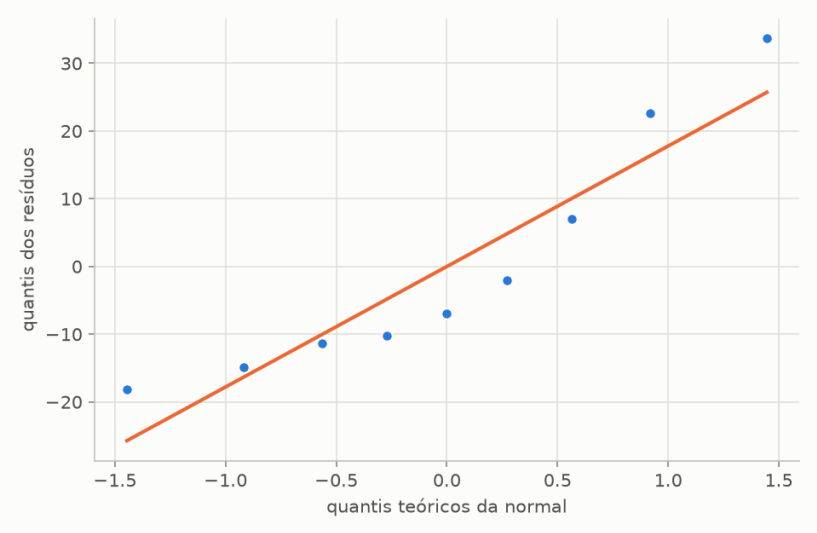


Figura IV: QQ-plot dos resíduos contra a distribuição normal (dados originais).

4. Premissas LINE

No gráfico de resíduos vs. valores preditos os resíduos formam um U, positivos nas duas pontas, com uns 34 mils no pneu novo e 23 na última medição, e negativos em todo o meio, chegando a -18, o que mostra que a premissa de função linear é violada. Como essa curva domina o gráfico, fica difícil avaliar a variância, mas não aparece um formato de funil, então não vemos sinal claro de variância desigual. No QQ-plot os pontos do meio ficam abaixo da reta e os dois maiores resíduos bem acima dela, e como esses dois são justamente as pontas do U, o pneu novo e a última medição, supomos que o desvio venha da curvatura, e com só 9 observações não dá para afirmar nem descartar a normalidade. Para a independência os gráficos pedidos não ajudam, e como o STAT501 não diz se as medições vêm de um pneu só, supomos que sejam medidas sucessivas do mesmo pneu, caso em que o erro de uma medição tende a se repetir na seguinte e a premissa fica questionável.

B. Exploração das transformações de escala

Para cada uma das nove combinações de transformações, ajustamos a reta sobre as variáveis transformadas e avaliamos o gráfico de dispersão resultante (Figura V). A Tabela II resume o R^2 ajustado e o número de observações de cada combinação, com a escolhida em negrito.

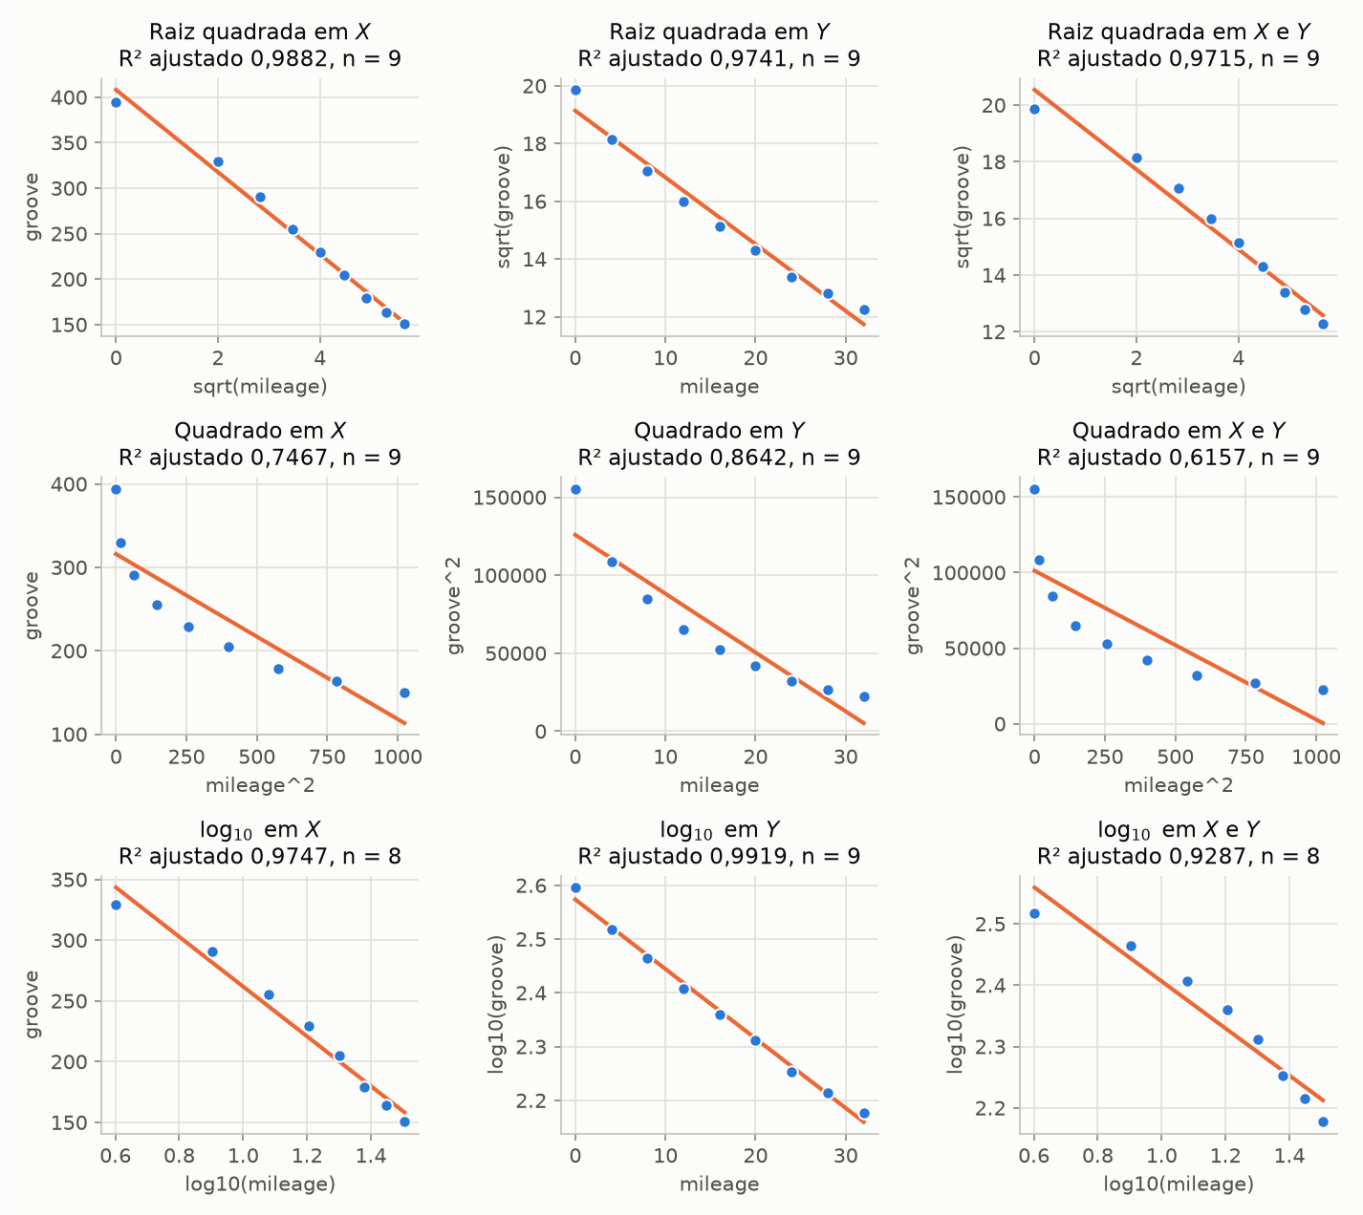


Figura V: Dispersão e reta ajustada para as nove combinações de transformações.

Transformação	**Aplicada em**	R^2 **ajustado**	n
Nenhuma	–	0,9458	9
Raiz quadrada	X	0,9882	9
Raiz quadrada	Y	0,9741	9
Raiz quadrada	X e Y	0,9715	9
Quadrado	X	0,7467	9
Quadrado	Y	0,8642	9
Quadrado	X e Y	0,6157	9
$\log_{10}$	X	0,9747	8
$\log_{10}$	**Y**	**0,9919**	**9**
$\log_{10}$	X e Y	0,9287	8

Tabela II: R^2 ajustado das combinações de transformações testadas no *dataset* Treadwear.

Nas combinações com $\log_{10}$ em X a primeira linha precisou ser removida, porque ela corresponde ao pneu novo,

com mileage igual a 0, e o logaritmo de zero não existe, por isso essas duas combinações têm $n = 8$. Pelos gráficos, as combinações com o quadrado deixam a curva ainda mais acentuada e a raiz quadrada só em Y endireita apenas parte dela. Já as combinações que transformam X com raiz quadrada ou $\log_{10}$, sozinho ou junto com Y, passam do ponto, deixando as medições das pontas abaixo da reta e as do meio acima, ou seja, uma curva no sentido contrário. A combinação em que os pontos ficam mais próximos de uma reta é o $\log_{10}$ só em Y, que também tem o maior R^2 ajustado (0,9919), e por isso foi a escolhida.

C. Análise da combinação escolhida

A combinação de transformações escolhida foi o logaritmo na base 10 aplicado somente sobre a variável resposta, ou seja, ajustamos $\log_{10}$(groove) em função de mileage.

1. Gráfico de dispersão

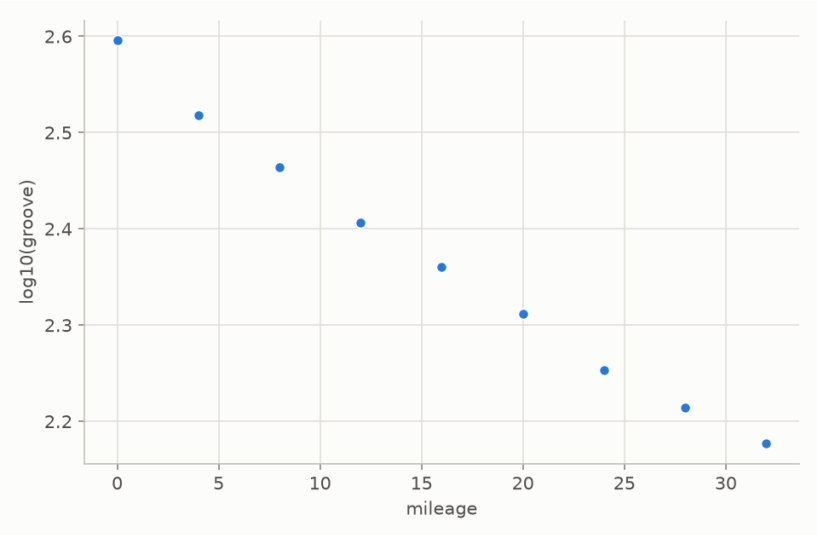


Figura VI: Dispersão entre as variáveis transformadas.

Depois da transformação os pontos ficam muito mais próximos de uma reta, com o $\log_{10}$ do groove caindo num ritmo quase constante conforme a quilometragem aumenta. Ainda dá para notar uma leve curvatura, com o pneu novo e a última medição um pouco acima da tendência dos pontos do meio, mas ela é bem menor do que nos dados originais.

2. Ajuste do modelo

OLS Regression Results

Dep. Variable:	log10(groove)	R-squared:	0.993
Model:	OLS	Adj. R-squared:	0.992
Method:	Least Squares	F-statistic:	976.3
		Prob (F-statistic):	8.88e-09
		Log-Likelihood:	27.570
No. Observations:	9	AIC:	-51.14
Df Residuals:	7	BIC:	-50.75
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	2.5736	0.008	326.576	0.000	2.555	2.592
mileage	-0.0129	0.000	-31.246	0.000	-0.014	-0.012

Omnibus:	2.879	Durbin-Watson:	1.033
Prob(Omnibus):	0.237	Jarque-Bera (JB):	1.551
Skew:	0.984	Prob(JB):	0.461
Kurtosis:	2.489	Cond. No.	35.2

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Tabela III: Resultados do ajuste por mínimos quadrados (dados transformados).

O R^2 ajustado subiu de 0,946 para 0,992, mas essa comparação é só indicativa, porque o novo valor mede a variação de $\log_{10}$(groove) e não do groove em si, então a melhora precisa ser confirmada nos gráficos de resíduos. A inclinação de $-0{,}0129$ significa que a cada mil milhas o groove previsto é multiplicado por $10^{-0{,}0129} \approx 0{,}97$, ou seja, o pneu perde uns 3% da profundidade restante a cada mil milhas, em vez de uma quantidade fixa de mils como no modelo original. No gráfico com os intervalos todas as 9 medições continuam dentro do intervalo de predição, com o pneu novo ainda um pouco acima da reta.

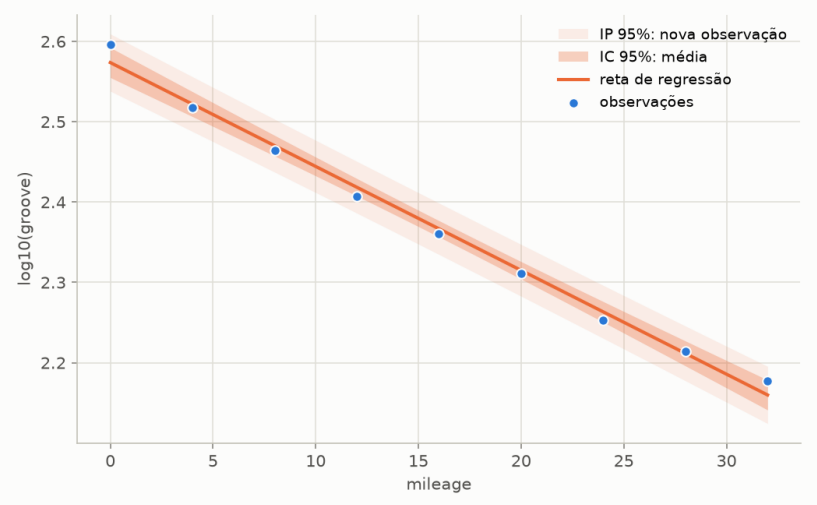


Figura VII: Reta de regressão com intervalos de confiança e de predição de 95% (dados transformados).

3. Análise dos resíduos

Pelo mesmo motivo da análise preliminar, o histograma dos resíduos continua de fora.

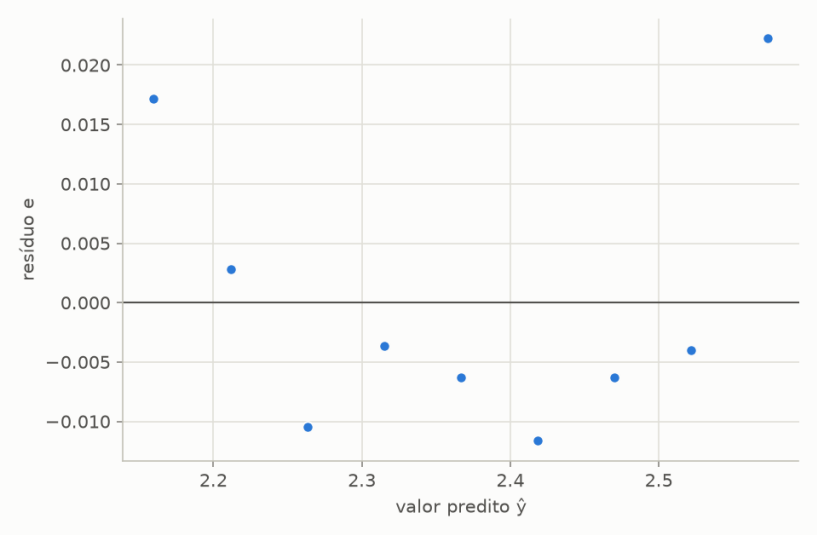


Figura VIII: Resíduos vs. valores preditos (dados transformados).

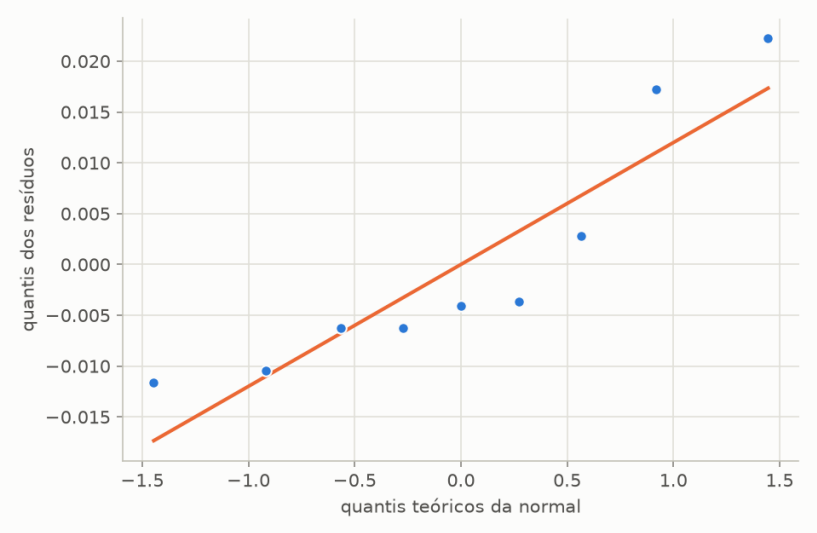


Figura IX: QQ-plot dos resíduos contra a distribuição normal (dados transformados).

4. Premissas LINE

O gráfico de resíduos vs. valores preditos ainda mostra o mesmo U, positivo nas pontas e negativo no meio, mas os erros ficaram bem menores em proporção ao groove. No pneu novo o resíduo de 0,022 em $\log_{10}$ equivale a um erro de uns 5%, contra 9% no modelo original, e na última medição o erro caiu de cerca de 18% para 4%. Assim a premissa de linearidade passa a ser atendida só em parte, e como o gráfico continua sem formato de funil, a variância segue parecendo constante. O QQ-plot mantém o mesmo desvio de antes, com os dois maiores resíduos acima da reta, o que com 9 observações ainda não permite concluir sobre a normalidade. A ressalva sobre a independência continua valendo, porque a transformação não muda a forma como as medições foram feitas.

III. Dataset Alligators

O *dataset* Alligators, apresentado na Subseção 4.7 do STAT501 [1], relaciona o peso de jacarés (`weight`, em libras, variável resposta Y) com o seu comprimento (`length`, em polegadas, variável preditora X), medidos numa amostra aleatória de 25 jacarés capturados por biólogos.

A. Análise preliminar sobre os dados originais

1. Gráfico de dispersão

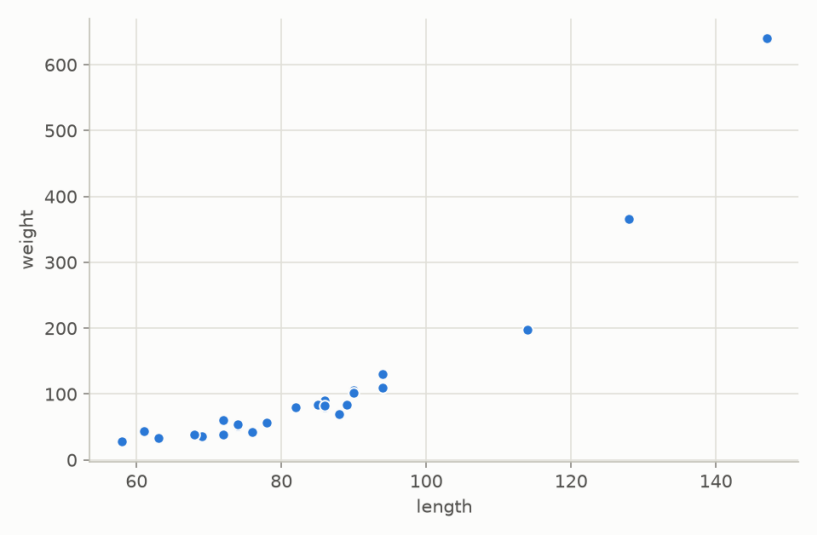


Figura X: Dispersão entre weight e length (dados originais).

O gráfico mostra uma associação positiva, mas não linear, com o weight crescendo cada vez mais rápido conforme o length aumenta, num formato parecido com uma exponencial. Entre 58 e 94 de length o weight sobe cerca de 3 por unidade, e entre 94 e 147 sobe cerca de 10. Os pontos se concentram nessa primeira faixa, com 22 dos 25 jacarés e pouca dispersão, e só 3 jacarés grandes e pesados ficam isolados à direita, deixando a curva evidente.

2. Ajuste do modelo

OLS Regression Results

Dep. Variable:	weight	R-squared:	0.836
Model:	OLS	Adj. R-squared:	0.829
Method:	Least Squares	F-statistic:	117.4
		Prob (F-statistic):	1.65e-10
		Log-Likelihood:	-134.16
No. Observations:	25	AIC:	272.3
Df Residuals:	23	BIC:	274.8
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	-393.2640	47.534	-8.273	0.000	-491.596	-294.932
length	5.9024	0.545	10.833	0.000	4.775	7.029

Omnibus:	12.483	Durbin-Watson:	1.627
Prob(Omnibus):	0.002	Jarque-Bera (JB):	11.509
Skew:	1.300	Prob(JB):	0.00317
Kurtosis:	5.071	Cond. No.	384.

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Tabela IV: Resultados do ajuste por mínimos quadrados (dados originais).

Com R^2 ajustado de 0,829 a reta explica uns 83% da variação do weight, o que à primeira vista parece um bom ajuste. A inclinação indica que cada polegada a mais de length soma em média 5,9 libras de weight, mas com o intercepto de -393 a reta prevê peso negativo para jacarés com menos de 67 polegadas, o que acontece com 3 dos 25 da amostra. No gráfico com os intervalos a reta passa abaixo dos jacarés menores, acima dos do meio e muito abaixo do maior, que é o único dos 25 fora do intervalo de predição, então apesar do R^2 razoável o modelo não captura bem

a forma da relação.

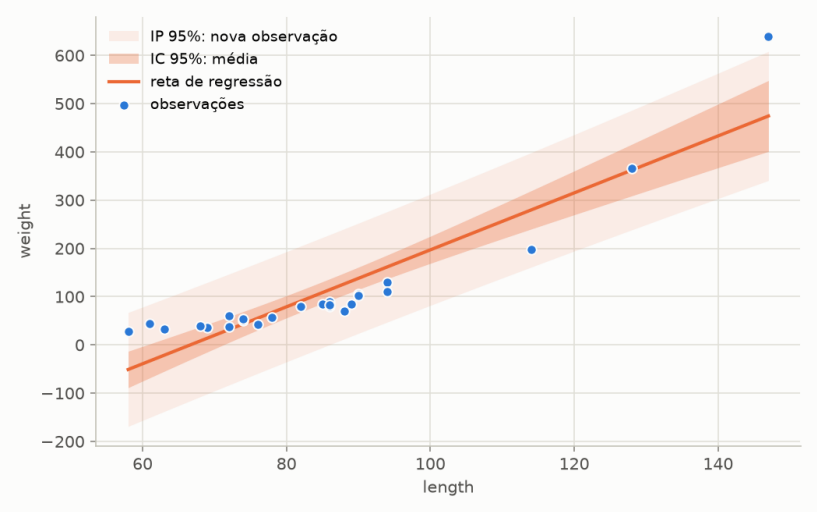


Figura XI: Reta de regressão com intervalos de confiança e de predição de 95% (dados originais).

3. Análise dos resíduos

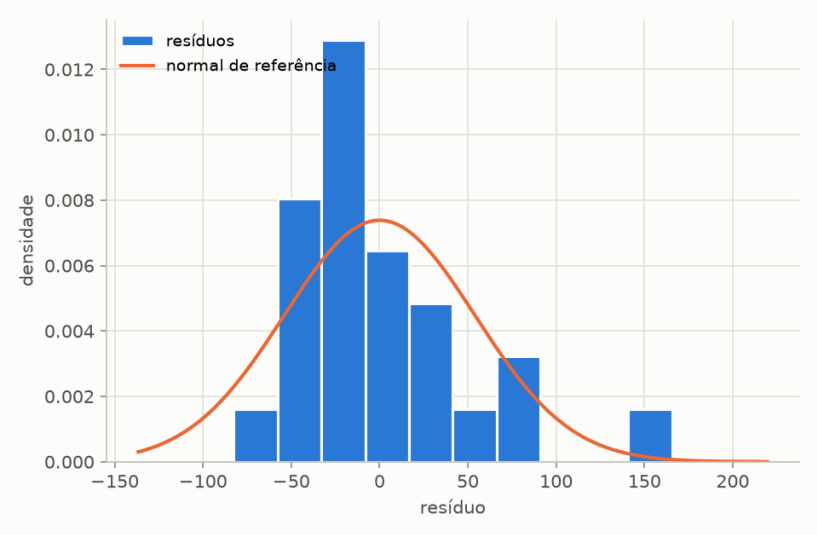


Figura XII: Histograma dos resíduos com a densidade normal de referência (dados originais).

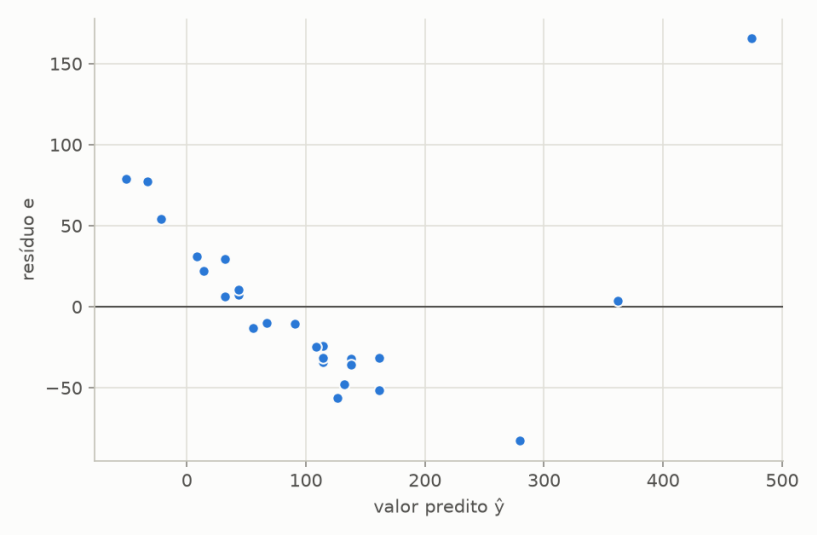


Figura XIII: Resíduos vs. valores preditos (dados originais).

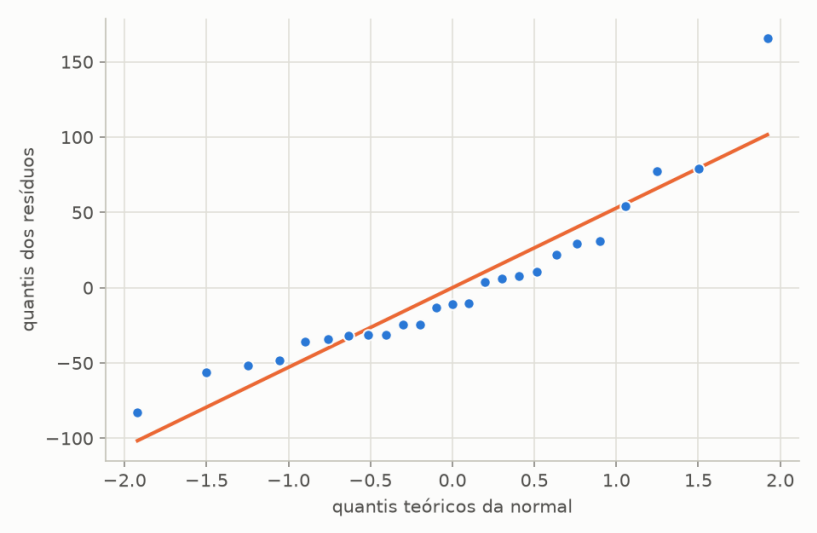


Figura XIV: QQ-plot dos resíduos contra a distribuição normal (dados originais).

4. Premissas LINE

No gráfico de resíduos vs. valores preditos os resíduos formam um U bem marcado, positivos para os menores valores preditos, negativos no meio e de novo muito positivos no maior jacaré, com resíduo de cerca de 166 libras, o que viola a premissa de linearidade. Com a curva dominando o gráfico fica difícil julgar a variância, mas os 3 maiores jacarés têm resíduos de −83, 4 e 166, uma faixa bem mais larga que a dos outros 22, entre −56 e 79, e supomos que a dispersão cresça com o tamanho do jacaré. O histograma é assimétrico à direita, com um resíduo isolado perto de 166, e o QQ-plot mostra a mesma coisa, com os menores resíduos acima da reta, os do meio abaixo e o de 166 bem acima na ponta, então a normalidade parece violada, e supomos que parte disso venha da curvatura que já quebra a linearidade. Quanto à independência, o STAT501 informa que os biólogos capturaram uma amostra aleatória de 25 jacarés, cada um sendo um animal diferente, então não há motivo para supor que o erro de um influencie o de outro e essa premissa parece razoável.

B. Exploração das transformações de escala

Como no Treadwear, a Figura XV mostra a dispersão e a reta de cada uma das nove combinações, e a Tabela V traz o R^2 ajustado e o n de cada uma, com a escolhida em negrito.

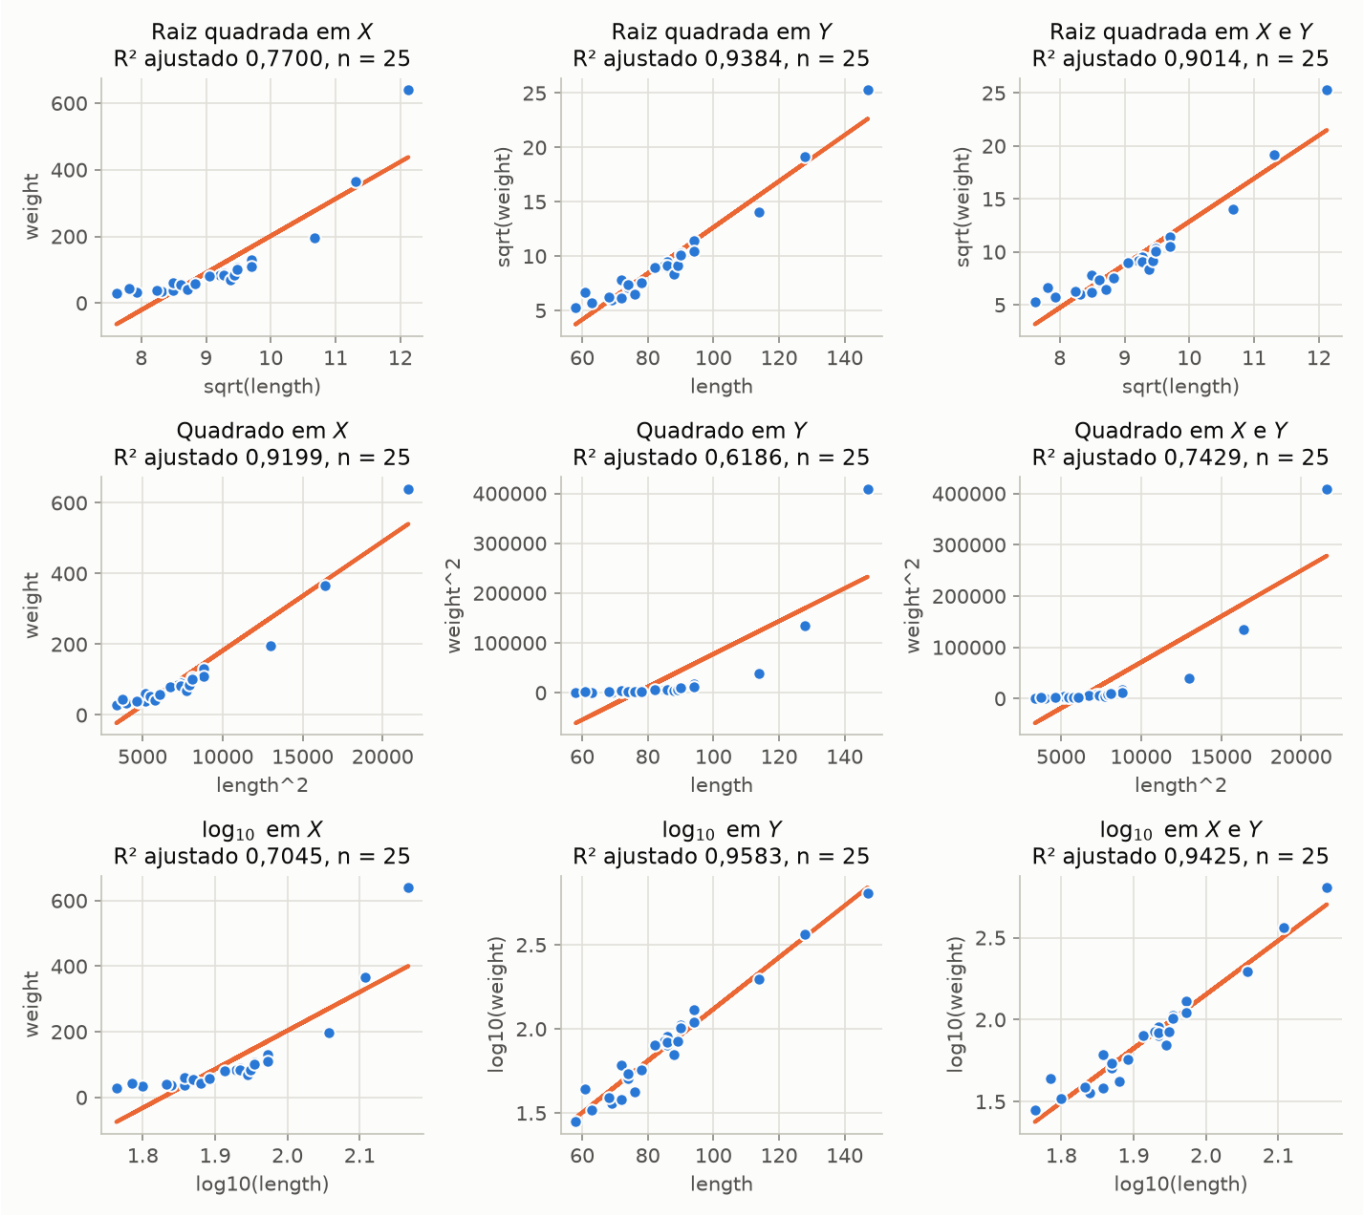


Figura XV: Dispersão e reta ajustada para as nove combinações de transformações.

Transformação	**Aplicada em**	R^2 **ajustado**	n
Nenhuma	–	0,8290	25
Raiz quadrada	X	0,7700	25
Raiz quadrada	Y	0,9384	25
Raiz quadrada	X e Y	0,9014	25
Quadrado	X	0,9199	25
Quadrado	Y	0,6186	25
Quadrado	X e Y	0,7429	25
$\log_{10}$	X	0,7045	25
$\log_{10}$	**Y**	**0,9583**	**25**
$\log_{10}$	X e Y	0,9425	25

Tabela V: R^2 ajustado das combinações de transformações testadas no *dataset* Alligators.

Nenhuma combinação precisou remover linhas, pois todos os valores de length e weight são positivos. A raiz

quadrada e o $\log_{10}$ só em X deixam a curva um pouco mais acentuada que a original, com R^2 ajustado caindo para 0,7700 e 0,7045, e o quadrado em Y, sozinho ou junto com X, piora ainda mais. O quadrado em X, a raiz quadrada em Y e as combinações em X e Y com raiz ou $\log_{10}$ endireitam boa parte da curva, mas ainda deixam algum dos 3 maiores jacarés fora do alinhamento dos demais. O $\log_{10}$ só em Y é a combinação em que os pontos ficam mais alinhados, sem curvatura visível, e também a de maior R^2 ajustado (0,9583). Isso combina com o formato parecido com uma exponencial que vimos nos dados originais, já que o logaritmo transforma um crescimento exponencial numa reta.

C. Análise da combinação escolhida

Assim como no Treadwear, ficamos com o $\log_{10}$ aplicado só no weight, ajustando $\log_{10}$(weight) em função de length.

1. Gráfico de dispersão

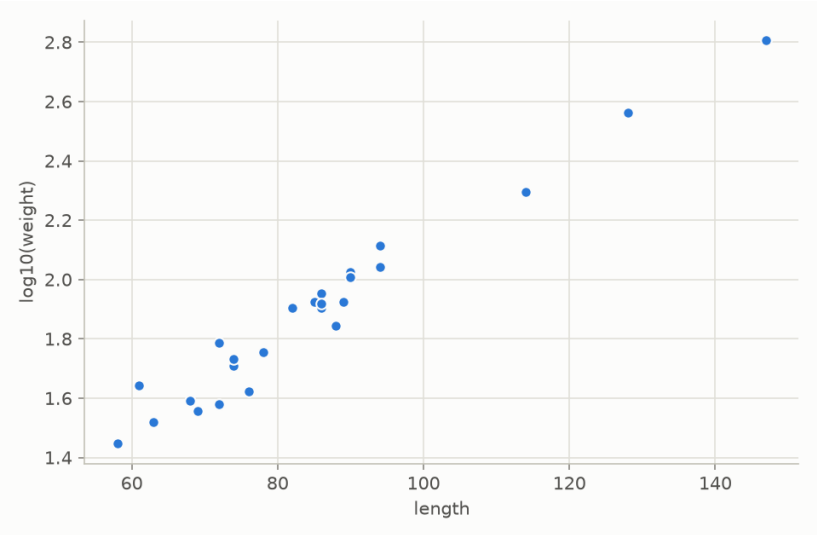


Figura XVI: Dispersão entre as variáveis transformadas.

Com o $\log_{10}$ no weight a associação fica claramente linear e positiva, com o $\log_{10}$ do weight crescendo num ritmo constante conforme o length aumenta, e os 3 jacarés grandes continuam isolados à direita, mas agora seguem a mesma tendência dos demais. Entre 58 e 94 polegadas a dispersão em torno da tendência fica mais ou menos constante, e com só 3 jacarés acima disso não dá para dizer muito sobre a ponta direita.

2. Ajuste do modelo

OLS Regression Results

Dep. Variable:	log10(weight)	R-squared:	0.960
Model:	OLS	Adj. R-squared:	0.958
Method:	Least Squares	F-statistic:	553.0
		Prob (F-statistic):	1.38e-17
		Log-Likelihood:	33.965
No. Observations:	25	AIC:	-63.93
Df Residuals:	23	BIC:	-61.49
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	0.5799	0.057	10.163	0.000	0.462	0.698
length	0.0154	0.001	23.515	0.000	0.014	0.017

Omnibus:	0.053	Durbin-Watson:	1.669
Prob(Omnibus):	0.974	Jarque-Bera (JB):	0.255
Skew:	-0.066	Prob(JB):	0.880
Kurtosis:	2.523	Cond. No.	384.

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Tabela VI: Resultados do ajuste por mínimos quadrados (dados transformados).

Com a transformação o R^2 ajustado foi de 0,829 para 0,958. Como o novo valor mede a variação de $\log_{10}(\text{weight})$ e não do weight, a comparação é só indicativa, mas aqui os gráficos de resíduos confirmam que o ajuste melhorou de fato. A inclinação de 0,0154 indica que cada polegada a mais de length multiplica o weight previsto por $10^{0,0154} \approx 1{,}036$, um aumento de uns 3,6% por polegada. Como qualquer valor de $\log_{10}(\text{weight})$ corresponde a um peso positivo, o modelo também deixa de prever pesos negativos, e no gráfico com os intervalos os 25 jacarés ficam dentro do intervalo de predição, inclusive o maior, que no modelo original ficava fora dele.

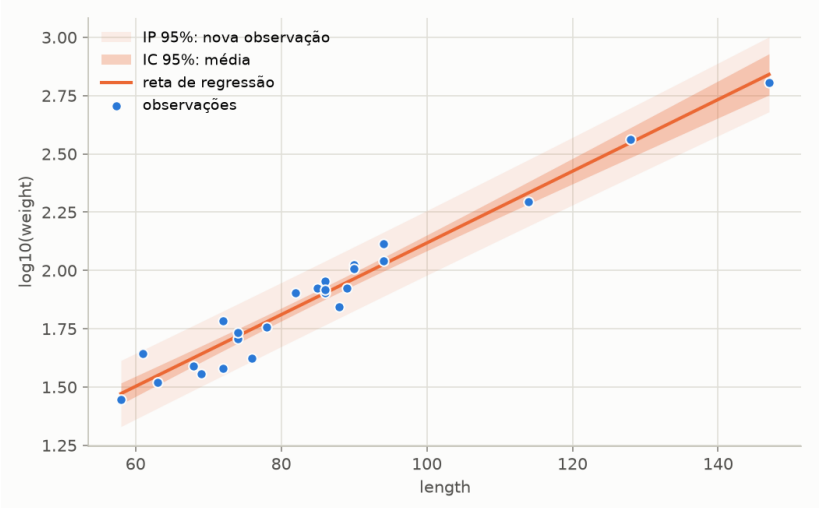


Figura XVII: Reta de regressão com intervalos de confiança e de predição de 95% (dados transformados).

3. Análise dos resíduos

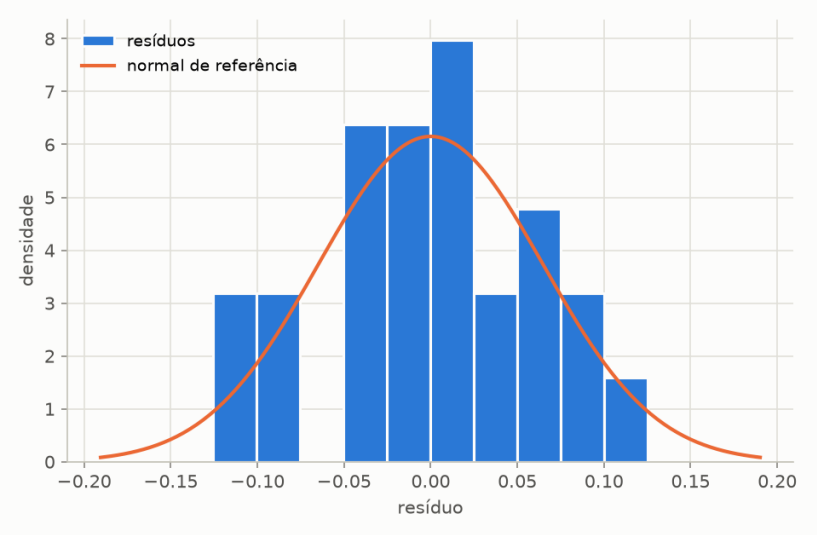


Figura XVIII: Histograma dos resíduos com a densidade normal de referência (dados transformados).

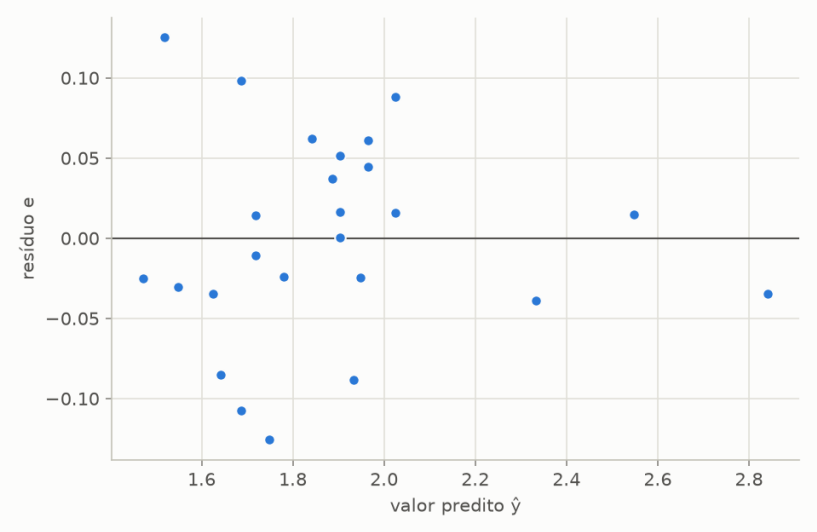


Figura XIX: Resíduos vs. valores preditos (dados transformados).

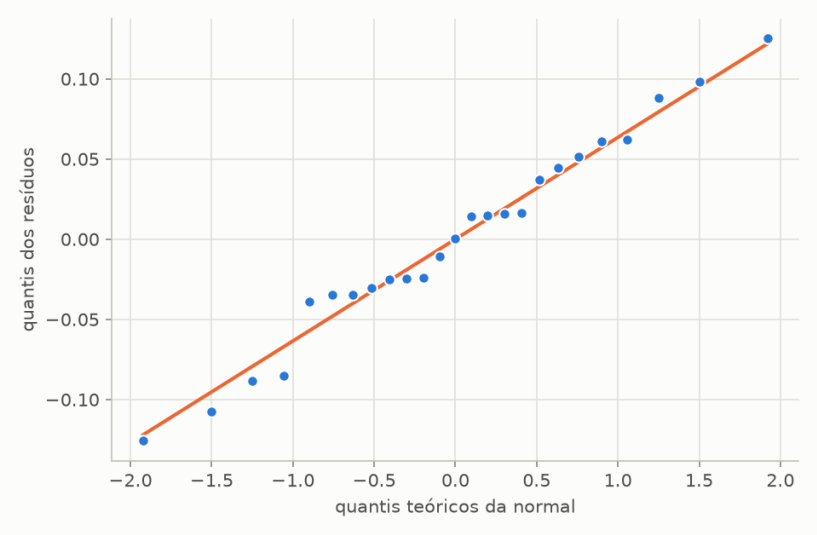


Figura XX: QQ-plot dos resíduos contra a distribuição normal (dados transformados).

4. Premissas LINE

O gráfico de resíduos vs. valores preditos passa a mostrar uma nuvem sem padrão em torno de zero, com resíduos entre cerca de $-0{,}13$ e $0{,}13$ e sem formato de funil, então as premissas de linearidade e de variância igual passam a ser atendidas. O histograma ficou próximo do formato de sino da normal de referência e no QQ-plot os pontos acompanham a reta de perto, inclusive nas pontas, então a normalidade também é atendida. A independência continua razoável pelo mesmo motivo da análise original, já que a transformação não muda a forma como os jacarés foram amostrados.

IV. Dataset ConcPatog

O *dataset* ConcPatog traz as concentrações de dois protozoários em água de esgoto tratado, medidas em diferentes estações de tratamento, estágios e meses do ano. O interesse é verificar se é possível estimar, com razoável acurácia, a concentração do patógeno 2 (`CPatog2`, variável resposta Y) a partir da concentração do patógeno 1 (`CPatog1`, variável preditora X).

A. Análise preliminar sobre os dados originais

1. Gráfico de dispersão

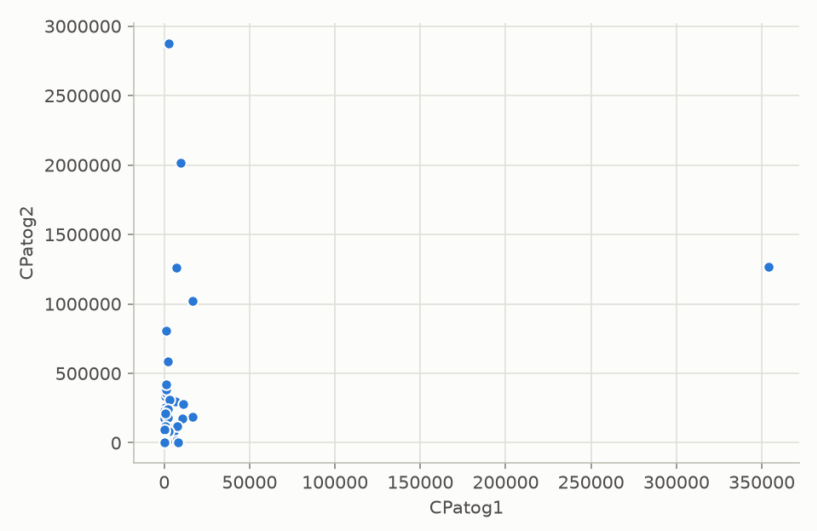


Figura XXI: Dispersão entre CPatog2 e CPatog1 (dados originais).

No gráfico original não há indício visual de associação linear, porque quase todos os pontos ficam espremidos perto da origem, com 104 dos 105 valores de CPatog1 abaixo de 17 mil e 98 dos valores de CPatog2 abaixo de 500 mil. Dentro desse aglomerado a dispersão de CPatog2 é muito grande, e alguns pontos extremos dominam o gráfico, como um único CPatog1 perto de 354 mil e quatro valores de CPatog2 acima de 1 milhão com CPatog1 baixo. As duas variáveis variam em várias ordens de grandeza, com CPatog1 indo de 0 a 354 mil (mediana 359) e CPatog2 de 4 a quase 3 milhões (mediana 13.900), e supomos que isso comprime os pontos e impede de enxergar uma tendência na escala original.

2. Ajuste do modelo

OLS Regression Results

Dep. Variable:	CPatog2	R-squared:	0.095
Model:	OLS	Adj. R-squared:	0.086
Method:	Least Squares	F-statistic:	10.81
		Prob (F-statistic):	0.00138
		Log-Likelihood:	-1497.3
No. Observations:	105	AIC:	2999.
Df Residuals:	103	BIC:	3004.
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	1.315e+05	3.76e+04	3.497	0.001	5.69e+04	2.06e+05
CPatog1	3.5583	1.082	3.288	0.001	1.412	5.705

Omnibus:	146.846	Durbin-Watson:	1.531
Prob(Omnibus):	0.000	Jarque-Bera (JB):	4365.918
Skew:	5.147	Prob(JB):	0.00
Kurtosis:	32.866	Cond. No.	3.51e+04

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 3.51e+04. This might indicate that there are
strong multicollinearity or other numerical problems.

Tabela VII: Resultados do ajuste por mínimos quadrados (dados originais).

A reta explica menos de 9% da variação de CPatog2, com R^2 ajustado de apenas 0,086, então o modelo não captura bem a variabilidade da resposta. A inclinação aparece como significativa ($p = 0{,}001$), mas esse valor depende das premissas LINE, que não valem aqui, e ela é muito influenciada pelo único ponto com CPatog1 perto de 354 mil, já que sem ele passaria de 3,6 para cerca de 43. No gráfico com os intervalos, o intervalo de predição chega a cerca de −630 mil para CPatog1 igual a 0, um valor que não faz sentido para uma concentração.

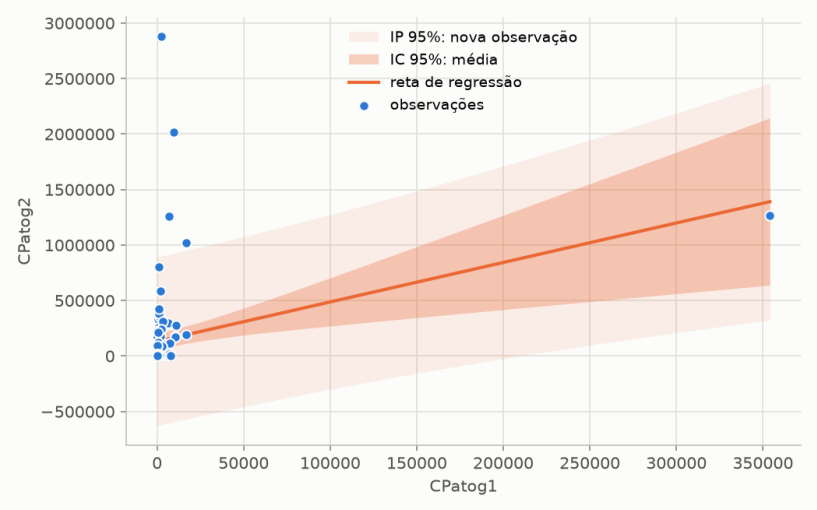


Figura XXII: Reta de regressão com intervalos de confiança e de predição de 95% (dados originais).

3. Análise dos resíduos

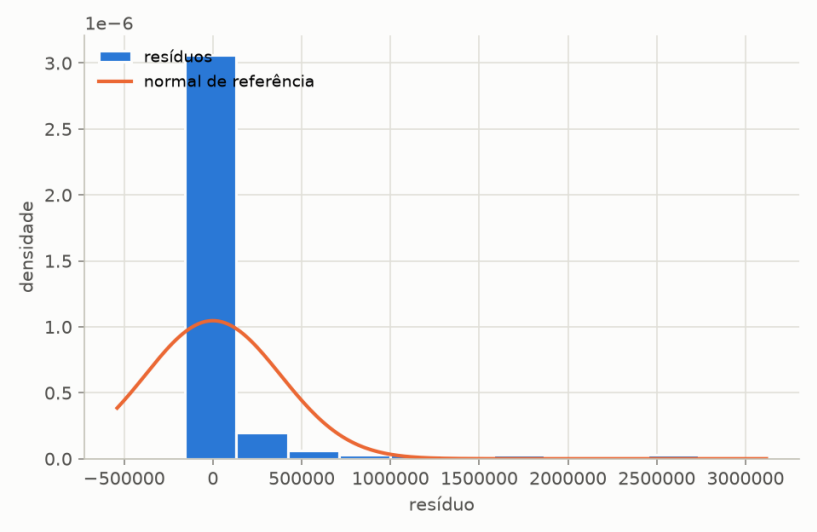


Figura XXIII: Histograma dos resíduos com a densidade normal de referência (dados originais).

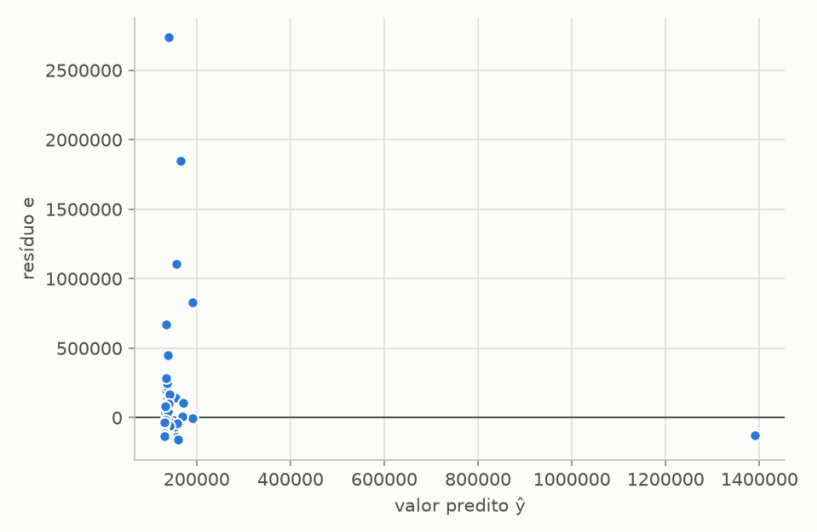


Figura XXIV: Resíduos vs. valores preditos (dados originais).

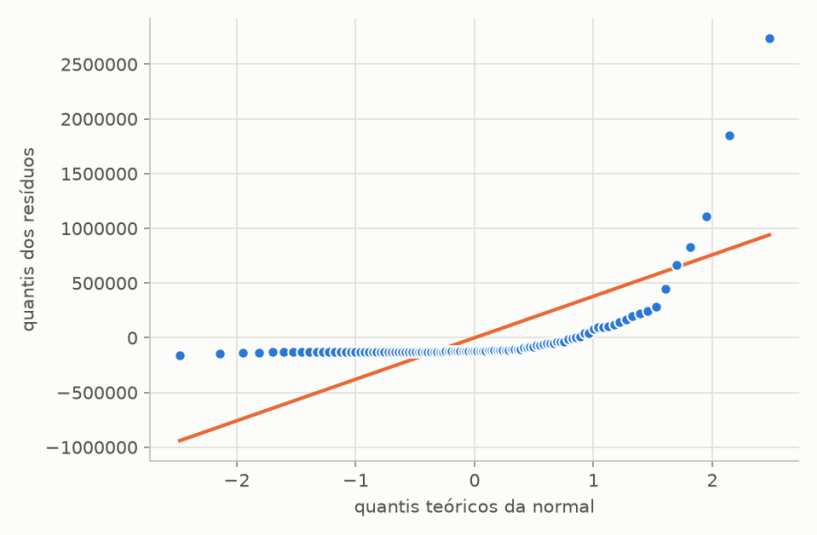


Figura XXV: QQ-plot dos resíduos contra a distribuição normal (dados originais).

4. Premissas LINE

No gráfico de resíduos vs. valores preditos quase todos os pontos ficam empilhados numa faixa estreita de valores preditos, entre 130 mil e 200 mil, com resíduos que vão de cerca de −160 mil a mais de 2,7 milhões, e só o ponto com CPatog1 perto de 354 mil fica fora dessa faixa. Além disso, 84 dos 105 resíduos são negativos, com mediana perto de −121 mil, então a reta passa acima da maioria dos pontos, puxada por poucos valores enormes, o que junto com o gráfico de dispersão indica que a premissa de linearidade não é atendida. Com os pontos empilhados assim também não dá para avaliar se a variância é constante ao longo dos valores preditos. O histograma é extremamente assimétrico à direita, com quase todos os resíduos numa única barra perto de zero e uma cauda longa, e no QQ-plot os pontos formam uma curva bem longe da reta, o que viola a premissa de normalidade. Quanto à independência, as 105 amostras vêm de 3 estações acompanhadas nos 12 meses, com até uma amostra de cada estágio por estação e mês, e supomos que amostras da mesma estação e do mesmo mês tenham erros parecidos entre si, o que tornaria essa premissa questionável.

B. Exploração das transformações de escala

As nove dispersões do ConcPatog estão na Figura XXVI, e a Tabela VIII mostra o R^2 ajustado e o n de cada combinação, com a escolhida em negrito.

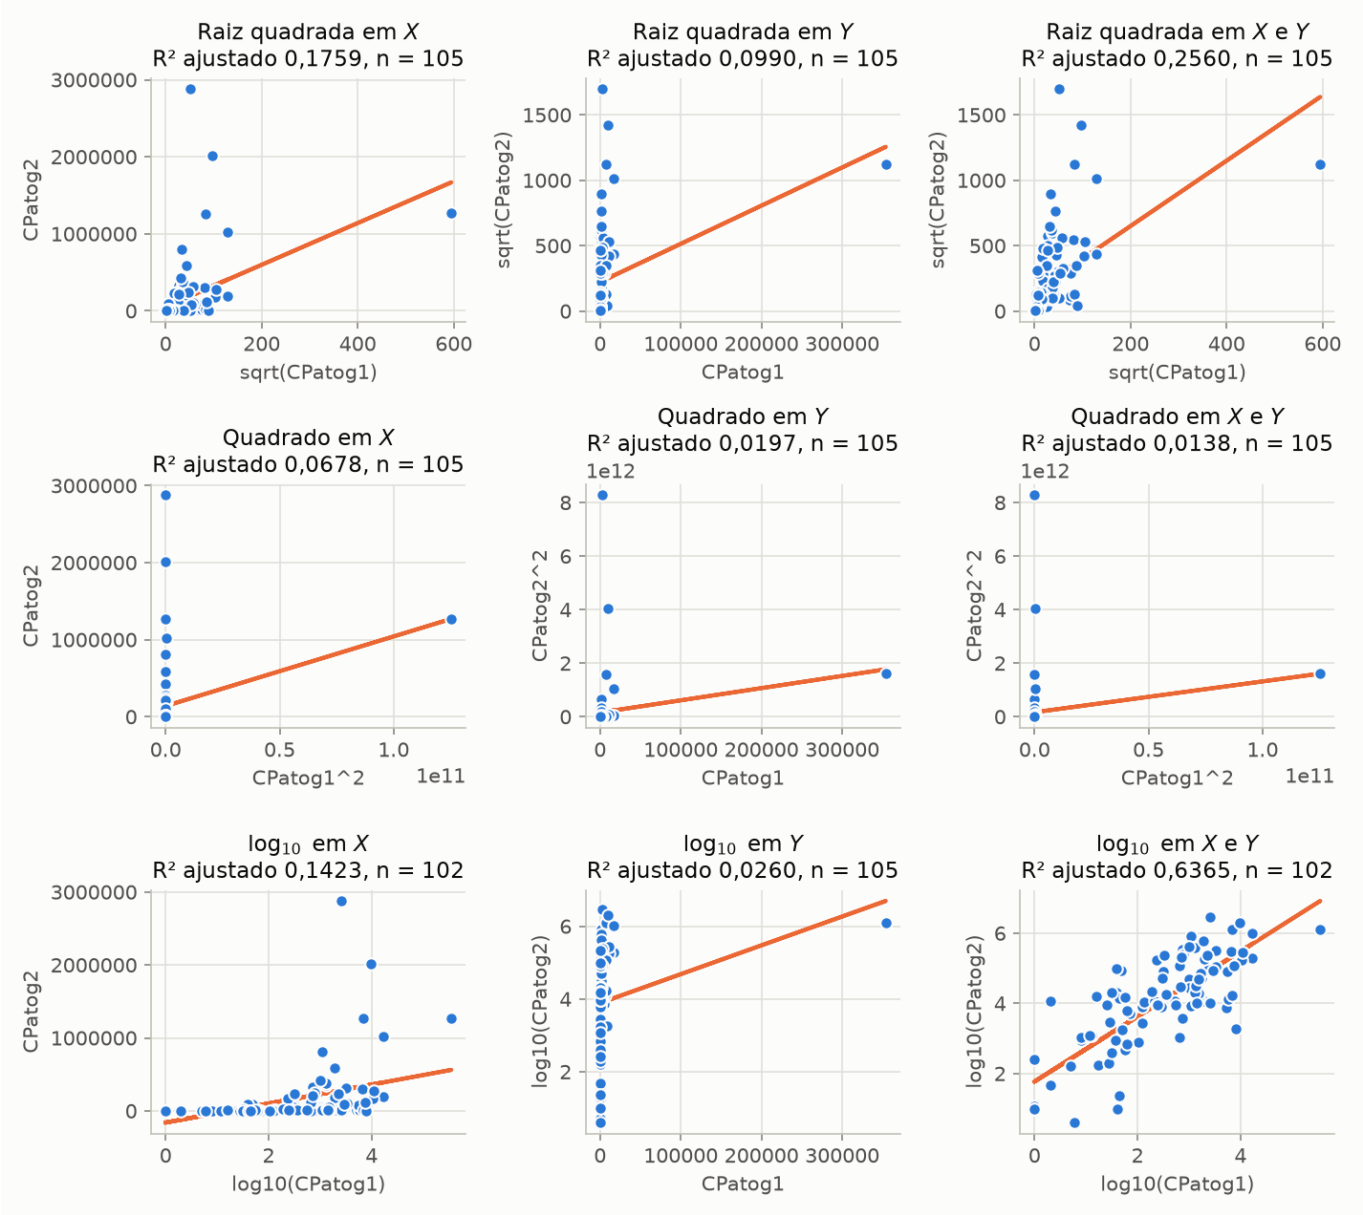


FIGURA XXVI: DISPERSÃO E RETA AJUSTADA PARA AS NOVE COMBINAÇÕES DE TRANSFORMAÇÕES.

Transformação	**Aplicada em**	R^2 **ajustado**	n
Nenhuma	–	0,0862	105
Raiz quadrada	X	0,1759	105
Raiz quadrada	Y	0,0990	105
Raiz quadrada	X e Y	0,2560	105
Quadrado	X	0,0678	105
Quadrado	Y	0,0197	105
Quadrado	X e Y	0,0138	105
$\log_{10}$	X	0,1423	102
$\log_{10}$	Y	0,0260	105
$\log_{10}$	***X* e *Y***	**0,6365**	**102**

TABELA VIII: R^2 AJUSTADO DAS COMBINAÇÕES DE TRANSFORMAÇÕES TESTADAS NO *dataset* CONCPATOG.

Nas combinações com $\log_{10}$ em X, as 3 amostras com CPatog1 igual a 0, todas do estágio de reúso, precisaram

ser removidas, porque o logaritmo de zero não existe, e por isso essas combinações têm $n = 102$. Preferimos remover essas linhas a somar uma constante antes do logaritmo, porque são só 3 de 105 amostras e o efeito de somar uma constante depende da unidade da variável. As combinações com quadrado e as que transformam só Y continuam com os pontos espremidos e dominados por poucos valores extremos. A raiz quadrada e o $\log_{10}$ só em X espalham melhor os valores de CPatog1, mas deixam CPatog2 concentrado perto de zero, e a raiz quadrada nas duas variáveis melhora um pouco, mas ainda deixa a maioria dos pontos perto da origem. Só com o $\log_{10}$ em X e Y os pontos se espalham pelo gráfico e mostram uma associação linear positiva clara, com R^2 ajustado de 0,6365, muito acima do de qualquer outra combinação, o que combina com o fato de as duas variáveis variarem em várias ordens de grandeza.

C. Análise da combinação escolhida

Aqui a escolha foi o $\log_{10}$ nas duas variáveis, com $\log_{10}$(CPatog2) ajustado em função de $\log_{10}$(CPatog1) e sem as 3 amostras com CPatog1 igual a 0.

1. Gráfico de dispersão

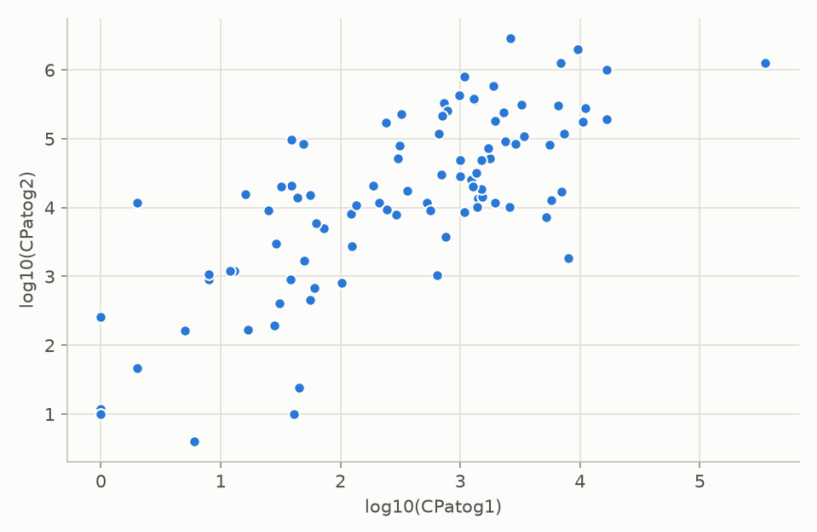


Figura XXVII: Dispersão entre as variáveis transformadas.

Na escala logarítmica os pontos deixam de ficar espremidos perto da origem e se espalham por todo o gráfico, mostrando uma associação linear positiva, em que amostras com mais do patógeno 1 tendem a ter mais do patógeno 2. A dispersão em torno da tendência ainda é grande, já que para valores parecidos de CPatog1 o CPatog2 chega a variar umas 4 unidades de $\log_{10}$, um fator de 10 mil. O ponto com CPatog1 perto de 354 mil, que antes dominava o gráfico, continua sozinho na ponta direita, mas agora fica perto da tendência dos demais.

2. Ajuste do modelo

OLS Regression Results

Dep. Variable:	log10(CPatog2)	R-squared:	0.640
Model:	OLS	Adj. R-squared:	0.637
Method:	Least Squares	F-statistic:	177.9
		Prob (F-statistic):	6.36e-24
		Log-Likelihood:	-126.16
No. Observations:	102	AIC:	256.3
Df Residuals:	100	BIC:	261.6
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	1.7698	0.188	9.437	0.000	1.398	2.142
log10(CPatog1)	0.9277	0.070	13.337	0.000	0.790	1.066

Omnibus:	0.569	Durbin-Watson:	1.651
Prob(Omnibus):	0.752	Jarque-Bera (JB):	0.321
Skew:	-0.132	Prob(JB):	0.852
Kurtosis:	3.078	Cond. No.	6.75

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Tabela IX: Resultados do ajuste por mínimos quadrados (dados transformados).

O ganho no R^2 ajustado é grande, de 0,086 para 0,637, mas a comparação é só indicativa, porque o novo valor mede a variação de $\log_{10}$(CPatog2) e não da concentração em si, e foi calculado sem as 3 amostras com CPatog1 igual a 0. A inclinação de 0,93 indica que, quando CPatog1 é multiplicado por 10, o CPatog2 previsto é multiplicado por $10^{0,93} \approx 8{,}5$, uma relação quase proporcional entre os dois patógenos. Mesmo assim o modelo não permite estimar CPatog2 com razoável acurácia para uma amostra individual, porque o intervalo de predição de 95% é muito largo. Para CPatog1 igual a 1.000, por exemplo, o CPatog2 previsto é de uns 36 mil, mas o intervalo vai de cerca de 750 a 1,7 milhão, então o valor real pode ficar até umas 50 vezes acima ou abaixo do previsto. O modelo serve então para indicar a tendência e a ordem de grandeza do CPatog2 típico, já que para o mesmo CPatog1 de 1.000 o intervalo de confiança vai só de cerca de 23 mil a 55 mil. Supomos ainda que parte da associação venha do estágio de tratamento, que reduz a concentração dos dois patógenos ao mesmo tempo.

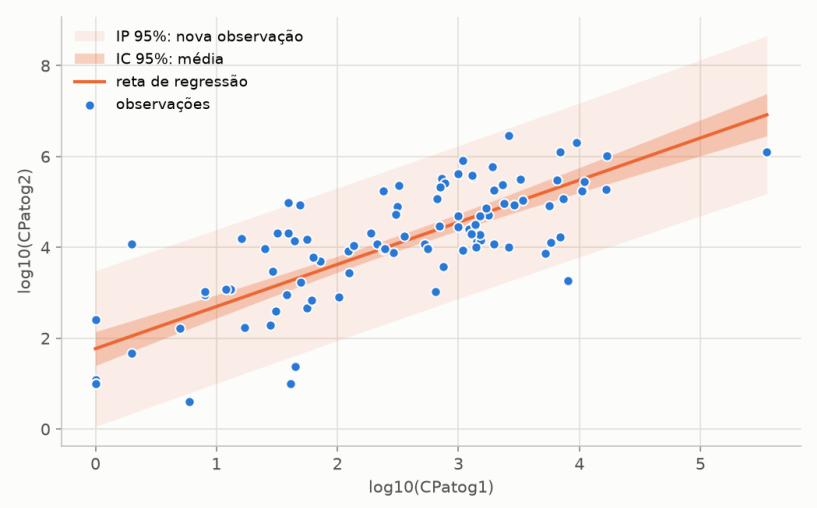


Figura XXVIII: Reta de regressão com intervalos de confiança e de predição de 95% (dados transformados).

3. Análise dos resíduos

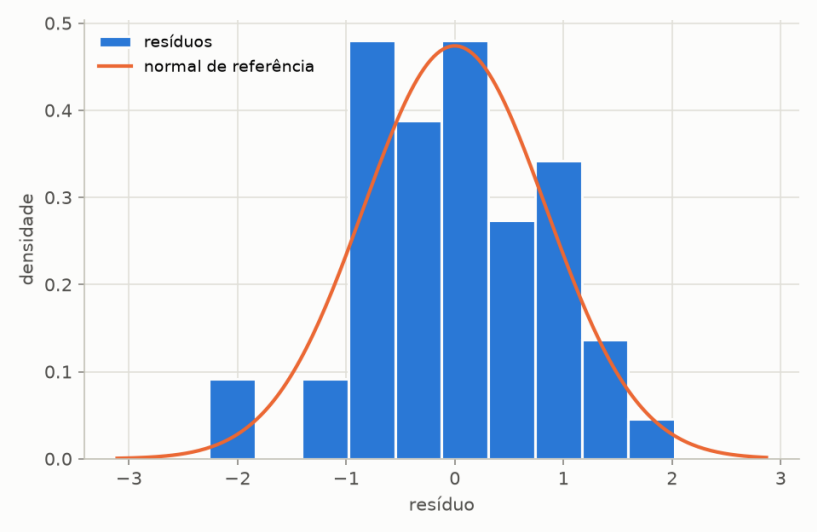


Figura XXIX: Histograma dos resíduos com a densidade normal de referência (dados transformados).

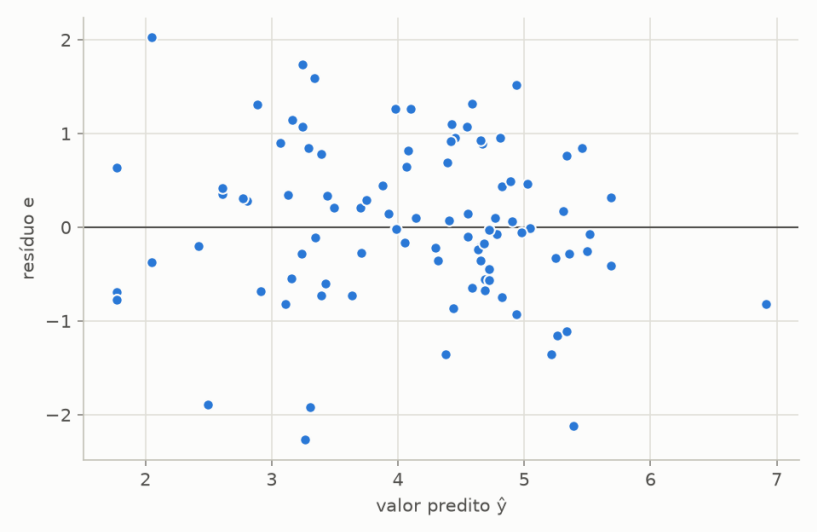


Figura XXX: Resíduos vs. valores preditos (dados transformados).

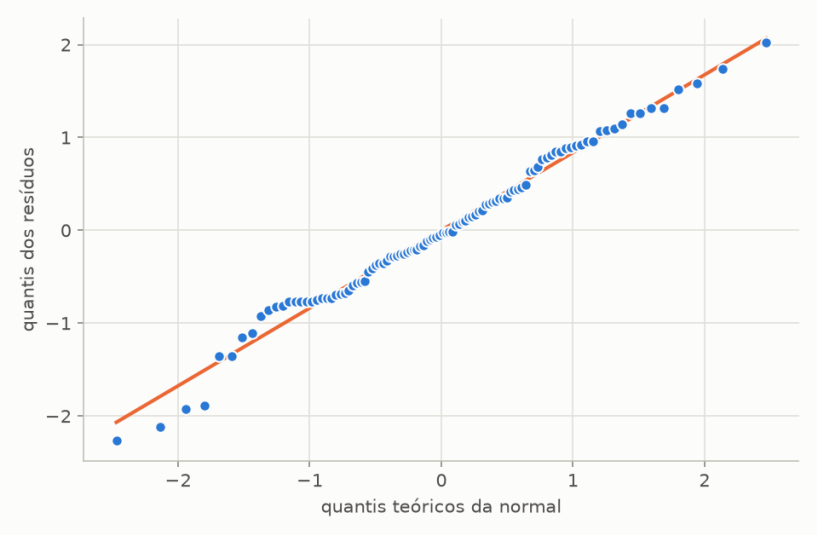


Figura XXXI: QQ-plot dos resíduos contra a distribuição normal (dados transformados).

4. Premissas LINE

Os resíduos em $\log_{10}$ se espalham ao acaso em torno de zero, entre cerca de $-2{,}3$ e $2{,}0$, com mais ou menos a mesma largura ao longo dos valores preditos, o que indica que as premissas de linearidade e de variância igual passam a valer. A normalidade também passa a valer, com o histograma perto da curva de referência e o QQ-plot quase todo em cima da reta, tirando um leve desvio na cauda inferior. A independência continua questionável, porque a transformação não muda o fato de as amostras serem agrupadas por estação, estágio e mês.

Referências

[1] THE PENNSYLVANIA STATE UNIVERSITY. **STAT 501: Regression Methods**. University Park: Eberly College of Science. Disponível em: `https://online.stat.psu.edu/stat501/`. Acesso em: 11 out. 2026.