Universidade de São Paulo
ACH2036 - Métodos Quantitativos para Análise Multivariada
Prof. Doutor: Marcelo de Souza Lauretto **Ano:** 2º Semestre/2026

Atividade 1 - Modelos de Regressão: Análise de resíduos e transformações de escala

Kauã Lima de Souza
15674702

Victor Yodono
13829040

I. Dataset Treadwear

O *dataset* Treadwear, apresentado na Subseção 4.4 do STAT501 [1], vem de um experimento de laboratório que relaciona a profundidade restante do sulco de um pneu (`groove`, em mils, variável resposta Y) com a distância rodada (`mileage`, em milhares de milhas, variável preditora X).

A. Análise preliminar sobre os dados originais

1. Gráfico de dispersão

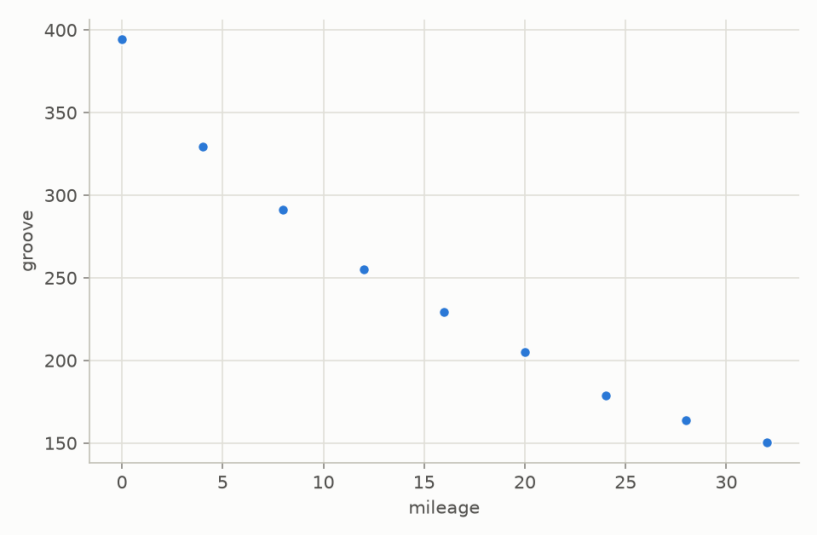


Figura I: Dispersão entre groove e mileage (Treadwear, dados originais).

O gráfico mostra uma associação negativa forte, que à primeira vista parece linear, com a profundidade do groove diminuindo conforme a distância rodada aumenta e pouca dispersão em torno da tendência. Olhando de perto, porém, os pontos desenham uma curva, pois o groove cai cerca de 65 mils nas primeiras 4 mil milhas e só cerca de 13 a 15 mils em cada um dos dois últimos trechos de 4 mil milhas, então uma reta passaria abaixo dos pontos nos extremos e acima no meio, o que indica que a relação não é exatamente linear.

2. Ajuste do modelo

OLS Regression Results

Dep. Variable:	groove	R-squared:	0.953
Model:	OLS	Adj. R-squared:	0.946
Method:	Least Squares	F-statistic:	140.7
		Prob (F-statistic):	6.87e-06
		Log-Likelihood:	-38.148
No. Observations:	9	AIC:	80.30
Df Residuals:	7	BIC:	80.69
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	360.6367	11.689	30.854	0.000	332.998	388.276
mileage	-7.2806	0.614	-11.862	0.000	-8.732	-5.829

Omnibus:	2.406	Durbin-Watson:	0.746
Prob(Omnibus):	0.300	Jarque-Bera (JB):	1.330
Skew:	0.900	Prob(JB):	0.514
Kurtosis:	2.445	Cond. No.	35.2

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Tabela I: Resultados do ajuste por mínimos quadrados (Treadwear, dados originais).

Na Tabela I, o R^2 é de 0,953 e o R^2 ajustado de 0,946, então a reta explica cerca de 95% da variação do groove, e a inclinação de $-7{,}28$ indica que o groove perde em média cerca de 7,3 mils a cada mil milhas rodadas. Olhando só para o R^2, o modelo parece capturar muito bem a variabilidade da resposta, mas o próprio STAT501 usa esse *dataset* para mostrar uma relação que não é linear, e um R^2 alto não garante que a reta seja a forma certa da relação. Na Figura II os pontos das pontas ficam acima da reta e os do meio abaixo dela, a mesma curva que já tínhamos visto na dispersão, mas todas as 9 medições caem dentro do intervalo de predição.

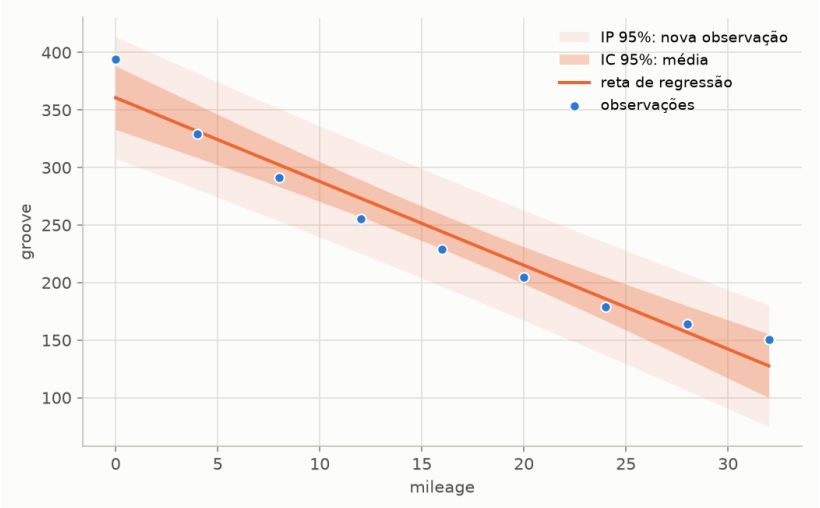


Figura II: Reta de regressão com intervalos de confiança e de predição de 95% (Treadwear, dados originais).

3. Análise dos resíduos

Deixamos o histograma dos resíduos de fora, como o enunciado orienta, porque com só 9 observações ele quase não mostra a forma da distribuição.

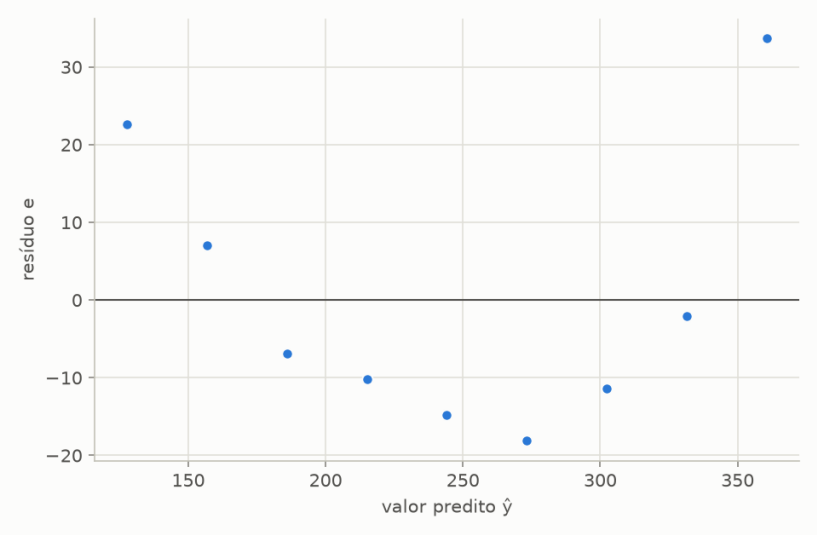


Figura III: Resíduos vs. valores preditos (Treadwear, dados originais).

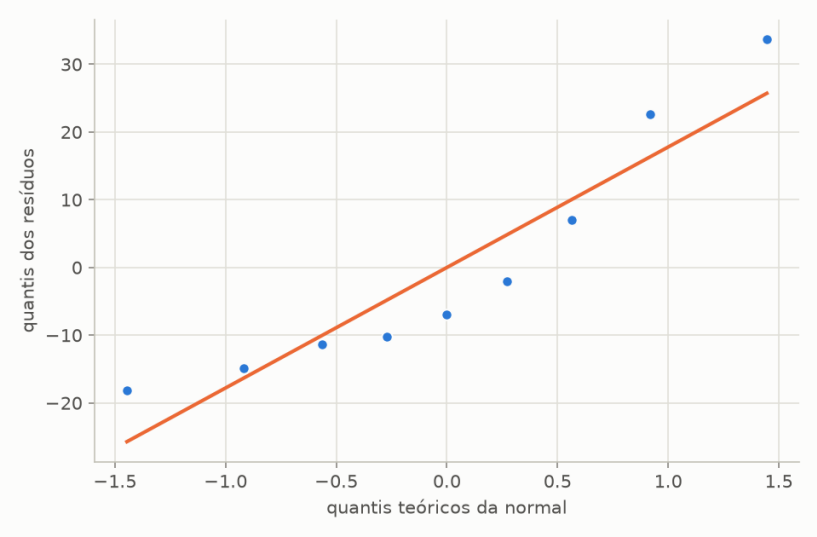


Figura IV: QQ-plot dos resíduos contra a distribuição normal (Treadwear, dados originais).

4. Premissas LINE

Linearidade (L) *Violada.* No gráfico de resíduos vs. valores preditos os resíduos formam um U, positivos nas duas pontas, com cerca de 34 mils no pneu novo e 23 na última medição, e negativos em todo o meio, chegando a -18.

Independência (I) *Questionável.* Os gráficos pedidos não ajudam a avaliar essa premissa, e como o STAT501 não diz se as medições vêm de um pneu só, supomos que sejam medidas sucessivas do mesmo pneu, caso em que o erro de uma medição tende a se repetir na seguinte.

Normalidade (N) *Inconclusiva.* No QQ-plot os pontos do meio ficam abaixo da reta e os dois maiores resíduos bem acima dela, e como esses dois são justamente as pontas do U, o pneu novo e a última medição, supomos que o desvio venha da curvatura, e com só 9 observações não dá para afirmar nem descartar a normalidade.

Variância igual (E) *Parece atendida.* Como a curva domina o gráfico, fica difícil avaliar a variância, mas não aparece um formato de funil, então não vemos sinal claro de variância desigual.

B. Exploração das transformações de escala

Para cada uma das nove combinações de transformações, ajustamos a reta sobre as variáveis transformadas e avaliamos o gráfico de dispersão resultante (Figura V). A Tabela II resume o R^2 ajustado e o número de observações

de cada combinação, com a escolhida em negrito.

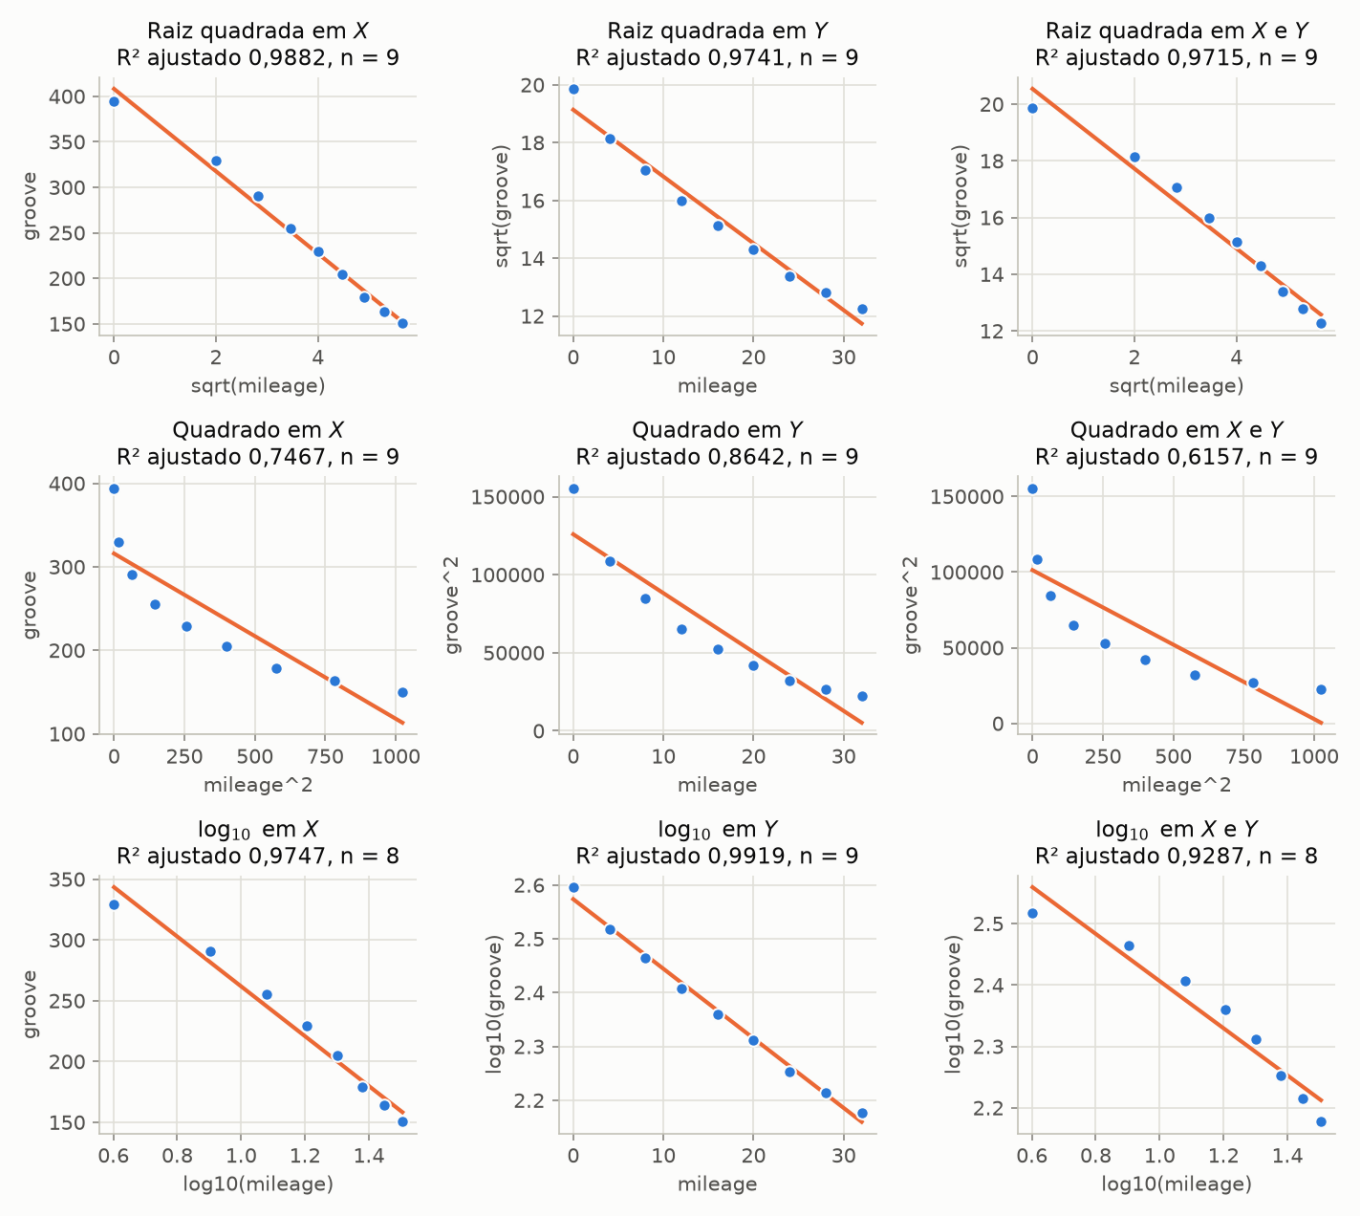


Figura V: Dispersão e reta ajustada para as nove combinações de transformações (Treadwear).

Transformação	**Aplicada em**	R^2 **ajustado**	n
Nenhuma	–	0,9458	9
Raiz quadrada	X	0,9882	9
Raiz quadrada	Y	0,9741	9
Raiz quadrada	X e Y	0,9715	9
Quadrado	X	0,7467	9
Quadrado	Y	0,8642	9
Quadrado	X e Y	0,6157	9
$\log_{10}$	X	0,9747	8
$\log_{10}$	**Y**	**0,9919**	**9**
$\log_{10}$	X e Y	0,9287	8

Tabela II: R^2 ajustado das combinações de transformações testadas no *dataset* Treadwear.

Nas combinações com $\log_{10}$ em X a primeira linha precisou ser removida, porque ela corresponde ao pneu novo, com mileage igual a 0, e o logaritmo de zero não existe, por isso essas duas combinações têm $n = 8$. Pelos gráficos, as combinações com o quadrado deixam a curva ainda mais acentuada e a raiz quadrada só em Y endireita apenas parte dela. Já as combinações que transformam X com raiz quadrada ou $\log_{10}$, sozinho ou junto com Y, passam do ponto, deixando as medições das pontas abaixo da reta e as do meio acima, ou seja, uma curva no sentido contrário. A combinação em que os pontos ficam mais próximos de uma reta é o $\log_{10}$ só em Y, que também tem o maior R^2 ajustado (0,9919), e por isso foi a escolhida.

C. Análise da combinação escolhida

A combinação de transformações escolhida foi o logaritmo na base 10 aplicado somente sobre a variável resposta, ou seja, ajustamos $\log_{10}$(groove) em função de mileage.

1. Gráfico de dispersão

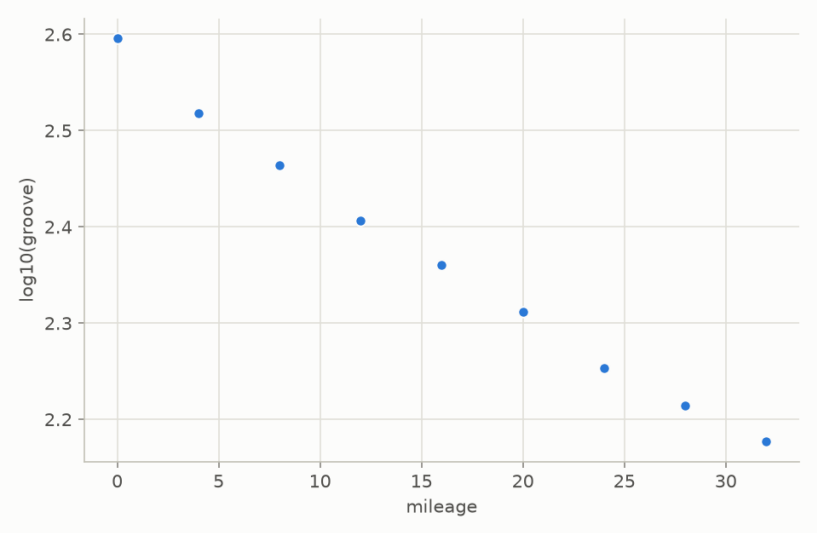


Figura VI: Dispersão entre $\log_{10}$(groove) e mileage (Treadwear, dados transformados).

Depois da transformação os pontos ficam muito mais próximos de uma reta, com o $\log_{10}$ do groove caindo num ritmo quase constante conforme a distância rodada aumenta. Ainda dá para notar uma leve curvatura, com o pneu novo e a última medição um pouco acima da tendência dos pontos do meio, mas ela é bem menor do que nos dados originais.

2. Ajuste do modelo

OLS Regression Results

Dep. Variable:	log10(groove)	R-squared:	0.993
Model:	OLS	Adj. R-squared:	0.992
Method:	Least Squares	F-statistic:	976.3
		Prob (F-statistic):	8.88e-09
		Log-Likelihood:	27.570
No. Observations:	9	AIC:	-51.14
Df Residuals:	7	BIC:	-50.75
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	2.5736	0.008	326.576	0.000	2.555	2.592
mileage	-0.0129	0.000	-31.246	0.000	-0.014	-0.012

Omnibus:	2.879	Durbin-Watson:	1.033
Prob(Omnibus):	0.237	Jarque-Bera (JB):	1.551
Skew:	0.984	Prob(JB):	0.461
Kurtosis:	2.489	Cond. No.	35.2

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Tabela III: Resultados do ajuste por mínimos quadrados (Treadwear, dados transformados).

O R^2 ajustado subiu de 0,946 para 0,992 (Tabela III), então, com base nesse indicador, o modelo transformado captura quase toda a variabilidade de $\log_{10}$(groove). A comparação com o modelo original, porém, é só indicativa, porque o novo valor mede a variação de $\log_{10}$(groove) e não do groove em si, então a melhora precisa ser confirmada nos gráficos de resíduos. A inclinação de $-0{,}0129$ significa que a cada mil milhas o groove previsto é multiplicado por $10^{-0{,}0129} \approx 0{,}97$, ou seja, o pneu perde uns 3% da profundidade restante a cada mil milhas, em vez de uma quantidade fixa de mils como no modelo original. No gráfico com os intervalos todas as 9 medições continuam dentro do intervalo de predição, com o pneu novo ainda um pouco acima da reta.

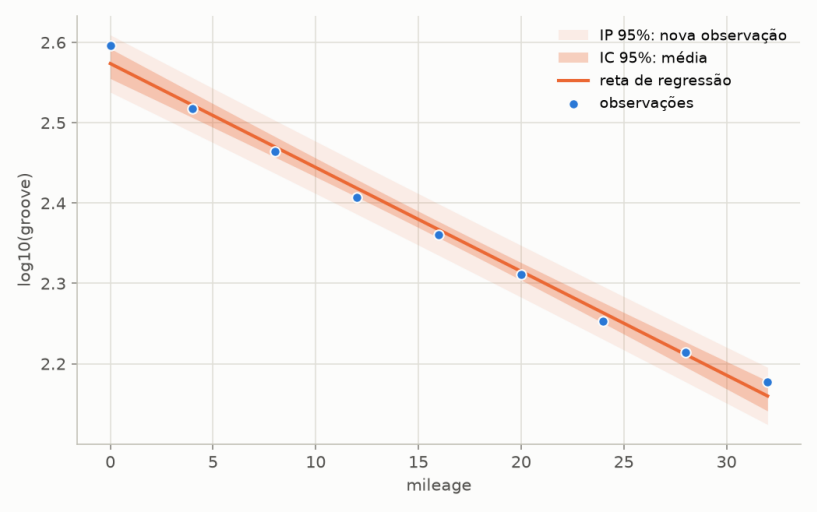


Figura VII: Reta de regressão com intervalos de confiança e de predição de 95% (Treadwear, dados transformados).

3. Análise dos resíduos

Pelo mesmo motivo da análise preliminar, o histograma dos resíduos continua de fora.

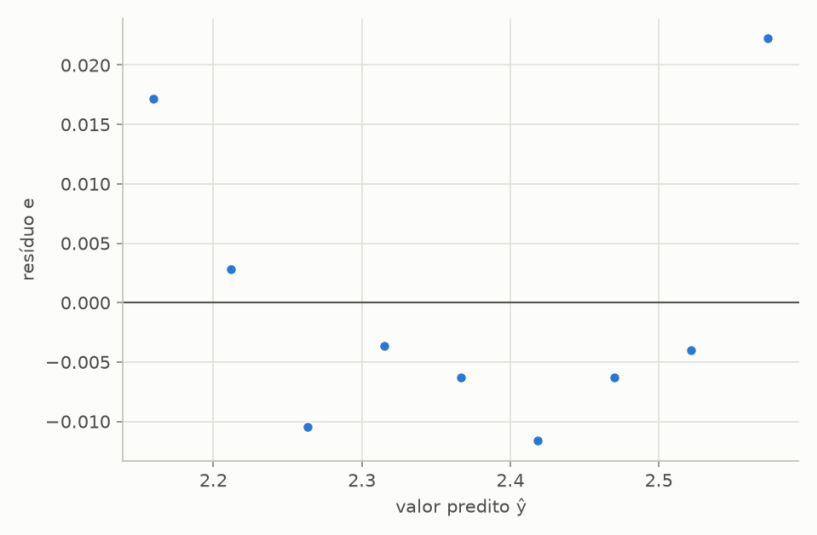


Figura VIII: Resíduos vs. valores preditos (Treadwear, dados transformados).

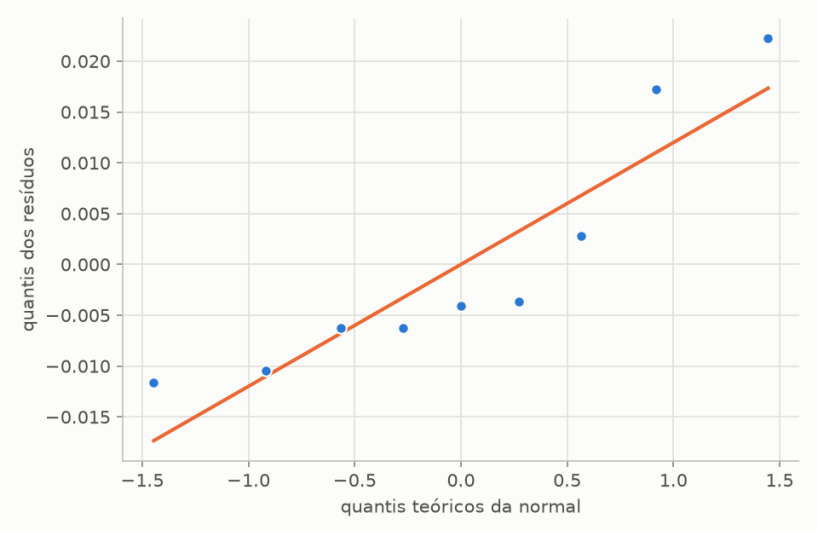


Figura IX: QQ-plot dos resíduos contra a distribuição normal (Treadwear, dados transformados).

4. Premissas LINE

Linearidade (L) *Atendida em parte.* O gráfico de resíduos vs. valores preditos ainda mostra o mesmo U, positivo nas pontas e negativo no meio, mas os erros ficaram bem menores em proporção ao groove, já que no pneu novo o resíduo de 0,022 em $\log_{10}$ equivale a um erro de uns 5%, contra 9% no modelo original, e na última medição o erro caiu de cerca de 18% para 4%.

Independência (I) *Questionável.* A transformação não muda a forma como as medições foram feitas, então continua valendo a suposição de que são medidas sucessivas do mesmo pneu.

Normalidade (N) *Inconclusiva.* O QQ-plot mantém o mesmo desvio de antes, com os dois maiores resíduos acima da reta, e com 9 observações ainda não dá para concluir sobre a normalidade.

Variância igual (E) *Parece atendida.* O gráfico de resíduos continua sem formato de funil.

II. Dataset Alligators

O *dataset* Alligators, apresentado na Subseção 4.7 do STAT501 [1], relaciona o peso de jacarés (`weight`, em libras, variável resposta Y) com o seu comprimento (`length`, em polegadas, variável preditora X), medidos numa amostra aleatória de 25 jacarés capturados por biólogos.

A. Análise preliminar sobre os dados originais

1. Gráfico de dispersão

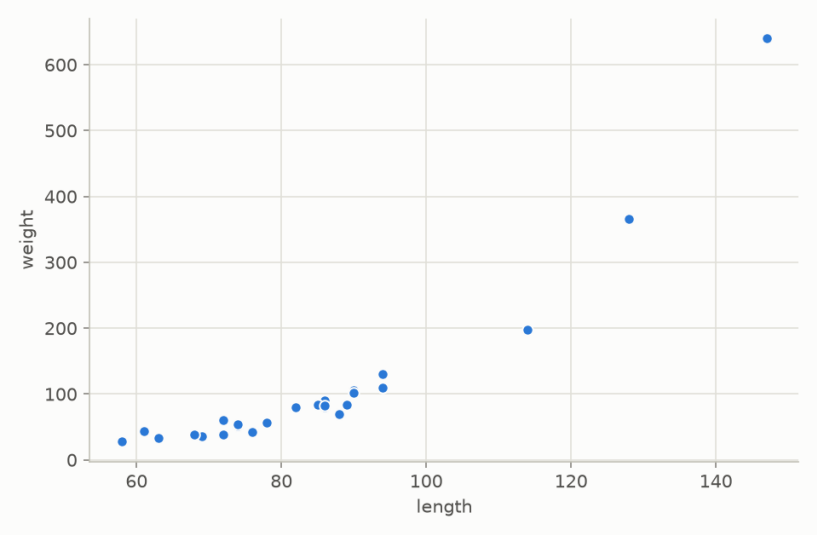


Figura X: Dispersão entre weight e length (Alligators, dados originais).

O gráfico mostra uma associação positiva, mas não linear, com o weight crescendo cada vez mais rápido conforme o length aumenta, num formato parecido com uma exponencial. Entre 58 e 94 polegadas o weight sobe cerca de 2,5 libras por polegada, e entre 94 e 147 sobe cerca de 10. Os pontos se concentram nessa primeira faixa, com 22 dos 25 jacarés e pouca dispersão, e só 3 jacarés grandes e pesados ficam isolados à direita, deixando a curva evidente.

2. Ajuste do modelo

OLS Regression Results

Dep. Variable:	weight	R-squared:	0.836
Model:	OLS	Adj. R-squared:	0.829
Method:	Least Squares	F-statistic:	117.4
		Prob (F-statistic):	1.65e-10
		Log-Likelihood:	-134.16
No. Observations:	25	AIC:	272.3
Df Residuals:	23	BIC:	274.8
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	-393.2640	47.534	-8.273	0.000	-491.596	-294.932
length	5.9024	0.545	10.833	0.000	4.775	7.029

Omnibus:	12.483	Durbin-Watson:	1.627
Prob(Omnibus):	0.002	Jarque-Bera (JB):	11.509
Skew:	1.300	Prob(JB):	0.00317
Kurtosis:	5.071	Cond. No.	384.

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Tabela IV: Resultados do ajuste por mínimos quadrados (Alligators, dados originais).

Com R^2 de 0,836 e R^2 ajustado de 0,829 (Tabela IV), a reta explica cerca de 84% da variação do weight, então, com base só nesse indicador, o modelo parece capturar bem a variabilidade da resposta. A inclinação indica que cada polegada a mais de length soma em média 5,9 libras de weight, mas com o intercepto de -393 a reta prevê peso negativo para jacarés com menos de 67 polegadas, o que acontece com 3 dos 25 da amostra. Na Figura XI a reta passa abaixo dos jacarés menores, acima dos do meio e muito abaixo do maior, que é o único dos 25 fora do intervalo de

predição, então apesar do R^2 alto o modelo não captura bem a forma da relação.

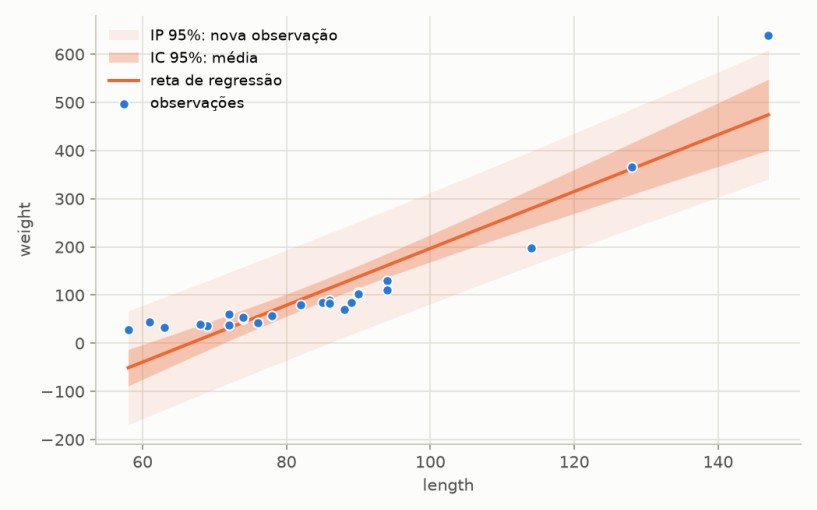


Figura XI: Reta de regressão com intervalos de confiança e de predição de 95% (Alligators, dados originais).

3. Análise dos resíduos

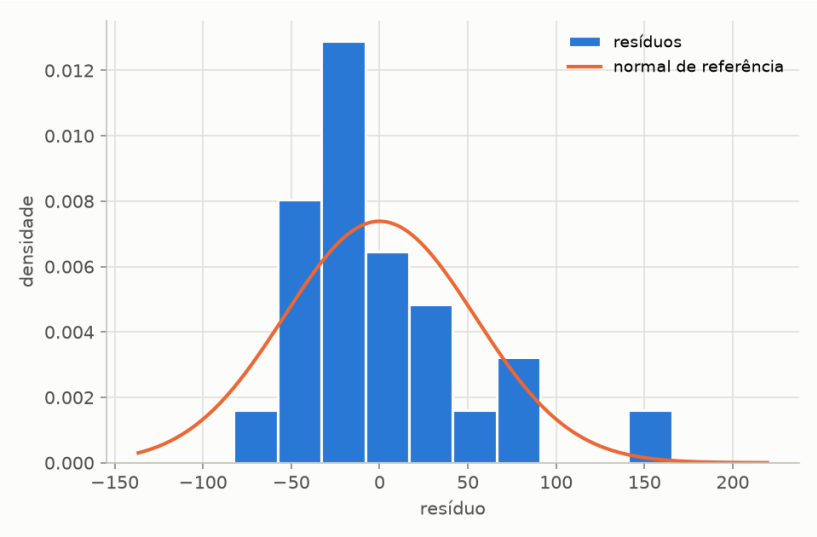


Figura XII: Histograma dos resíduos com a densidade normal de referência (Alligators, dados originais).

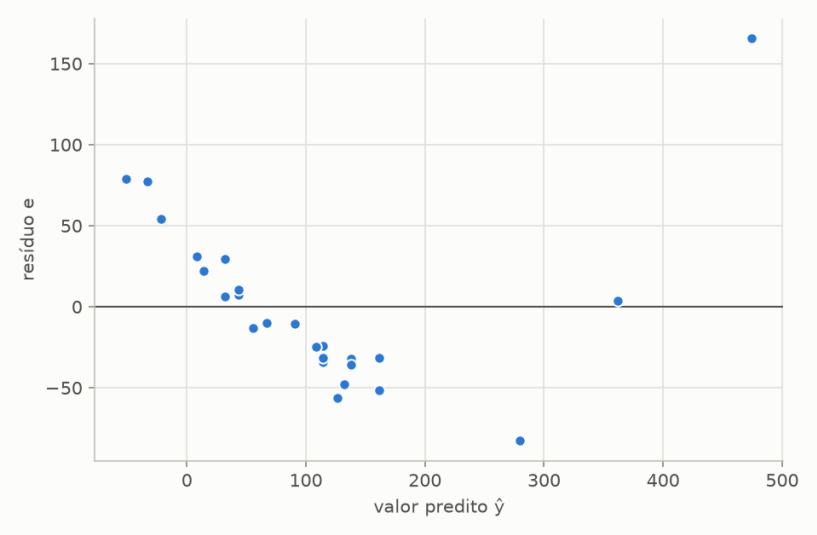


Figura XIII: Resíduos vs. valores preditos (Alligators, dados originais).

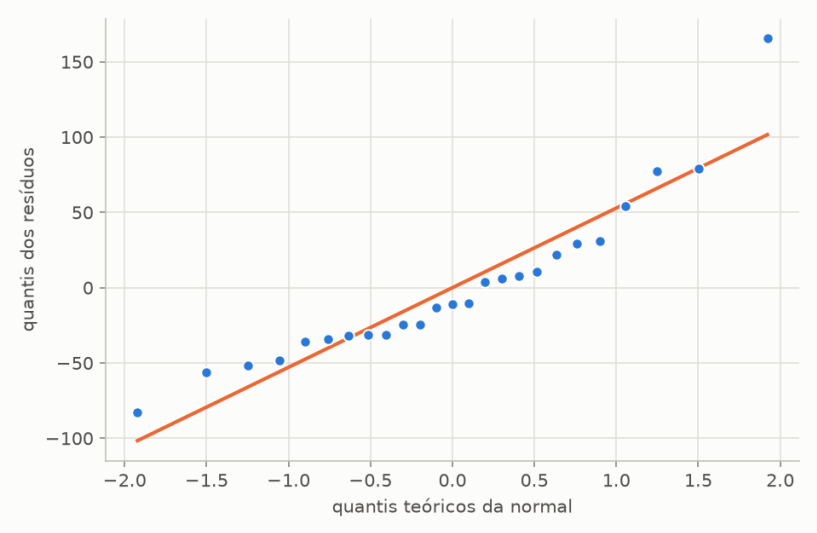


Figura XIV: QQ-plot dos resíduos contra a distribuição normal (Alligators, dados originais).

4. Premissas LINE

Linearidade (L) *Violada.* No gráfico de resíduos vs. valores preditos os resíduos formam um U bem marcado, positivos para os menores valores preditos, negativos no meio e de novo bem positivo no maior jacaré, com resíduo de cerca de 166 libras.

Independência (I) *Parece atendida.* O STAT501 informa que os biólogos capturaram uma amostra aleatória de 25 jacarés, cada um sendo um animal diferente, então não há motivo para supor que o erro de um influencie o de outro.

Normalidade (N) *Parece violada.* O histograma é assimétrico à direita, com um resíduo isolado perto de 166, e o QQ-plot mostra a mesma coisa, com os menores resíduos acima da reta, os do meio abaixo e o de 166 bem acima na ponta, e supomos que parte disso venha da curvatura que já quebra a linearidade.

Variância igual (E) *Parece violada.* Com a curva dominando o gráfico, fica difícil julgar a variância, mas os 3 maiores jacarés têm resíduos de -83, 4 e 166, uma faixa bem mais larga que a dos outros 22, entre -56 e 79, e supomos que a dispersão cresça com o tamanho do jacaré.

B. Exploração das transformações de escala

Como no Treadwear, a Figura XV mostra a dispersão e a reta de cada uma das nove combinações, e a Tabela V traz o R^2 ajustado e o n de cada uma, com a escolhida em negrito.

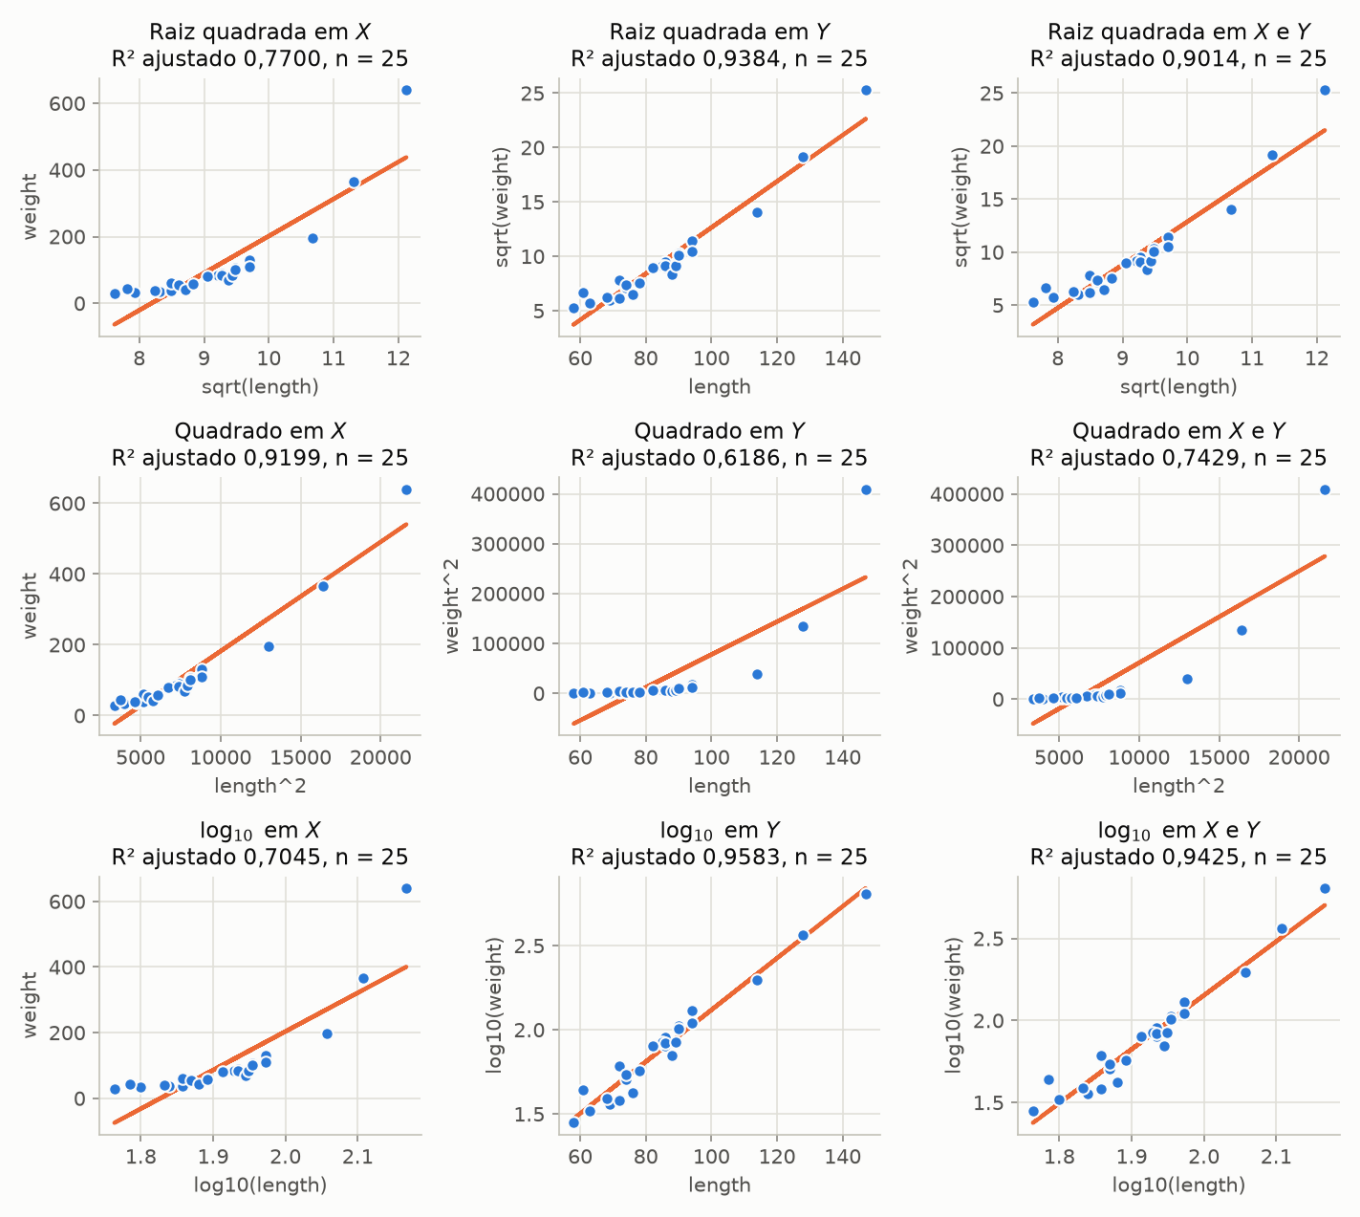


Figura XV: Dispersão e reta ajustada para as nove combinações de transformações (Alligators).

Transformação	**Aplicada em**	R^2 **ajustado**	n
Nenhuma	–	0,8290	25
Raiz quadrada	X	0,7700	25
Raiz quadrada	Y	0,9384	25
Raiz quadrada	X e Y	0,9014	25
Quadrado	X	0,9199	25
Quadrado	Y	0,6186	25
Quadrado	X e Y	0,7429	25
$\log_{10}$	X	0,7045	25
$\log_{10}$	***Y***	**0,9583**	**25**
$\log_{10}$	X e Y	0,9425	25

Tabela V: R^2 ajustado das combinações de transformações testadas no *dataset* Alligators.

Nenhuma combinação precisou remover linhas, pois todos os valores de length e weight são positivos. A raiz quadrada e o $\log_{10}$ só em X deixam a curva um pouco mais acentuada que a original, com R^2 ajustado caindo para 0,7700 e 0,7045, e o quadrado em Y, sozinho ou junto com X, também deixa a curva mais acentuada que a original, com R^2 ajustado de 0,6186 e 0,7429. O quadrado em X, a raiz quadrada em Y e as combinações em X e Y com raiz ou $\log_{10}$ endireitam boa parte da curva, mas ainda deixam algum dos 3 maiores jacarés fora do alinhamento dos demais. O $\log_{10}$ só em Y é a combinação em que os pontos ficam mais alinhados, sem curvatura visível, e também a de maior R^2 ajustado (0,9583). Isso combina com o formato parecido com uma exponencial que vimos nos dados originais, já que o logaritmo transforma um crescimento exponencial numa reta.

C. Análise da combinação escolhida

Assim como no Treadwear, ficamos com o $\log_{10}$ aplicado só no weight, ajustando $\log_{10}$(weight) em função de length.

1. Gráfico de dispersão

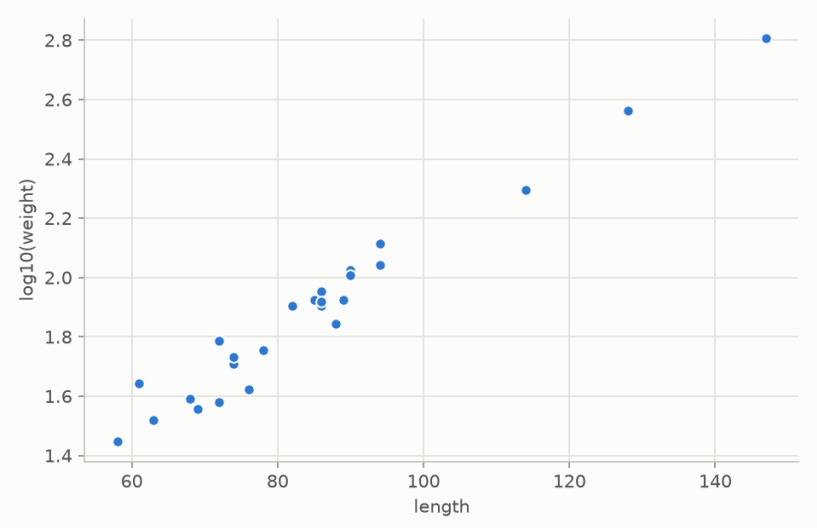


Figura XVI: Dispersão entre $\log_{10}$(weight) e length (Alligators, dados transformados).

Com o $\log_{10}$ no weight a associação fica claramente linear e positiva, com o $\log_{10}$ do weight crescendo num ritmo constante conforme o length aumenta, e os 3 jacarés grandes continuam isolados à direita, mas agora seguem a mesma tendência dos demais. Entre 58 e 94 polegadas a dispersão em torno da tendência fica mais ou menos constante, e com só 3 jacarés acima disso não dá para dizer muito sobre a ponta direita.

2. Ajuste do modelo

OLS Regression Results

Dep. Variable:	log10(weight)	R-squared:	0.960
Model:	OLS	Adj. R-squared:	0.958
Method:	Least Squares	F-statistic:	553.0
		Prob (F-statistic):	1.38e-17
		Log-Likelihood:	33.965
No. Observations:	25	AIC:	-63.93
Df Residuals:	23	BIC:	-61.49
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	0.5799	0.057	10.163	0.000	0.462	0.698
length	0.0154	0.001	23.515	0.000	0.014	0.017

Omnibus:	0.053	Durbin-Watson:	1.669
Prob(Omnibus):	0.974	Jarque-Bera (JB):	0.255
Skew:	-0.066	Prob(JB):	0.880
Kurtosis:	2.523	Cond. No.	384.

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Tabela VI: Resultados do ajuste por mínimos quadrados (Alligators, dados transformados).

Com a transformação o R^2 ajustado foi de 0,829 para 0,958 (Tabela VI), e, com base nesse indicador, o modelo passa a capturar bem a variabilidade de $\log_{10}$(weight). Vale aqui a mesma ressalva do Treadwear sobre comparar R^2 de respostas em escalas diferentes, mas neste caso os gráficos de resíduos confirmam que o ajuste melhorou de fato. A inclinação de 0,0154 indica que cada polegada a mais de length multiplica o weight previsto por $10^{0,0154} \approx 1{,}036$, um aumento de cerca de 3,6% por polegada. Como qualquer valor de $\log_{10}$(weight) corresponde a um peso positivo, o modelo também deixa de prever pesos negativos, e no gráfico com os intervalos os 25 jacarés ficam dentro do intervalo de predição, inclusive o maior, que no modelo original ficava fora dele.

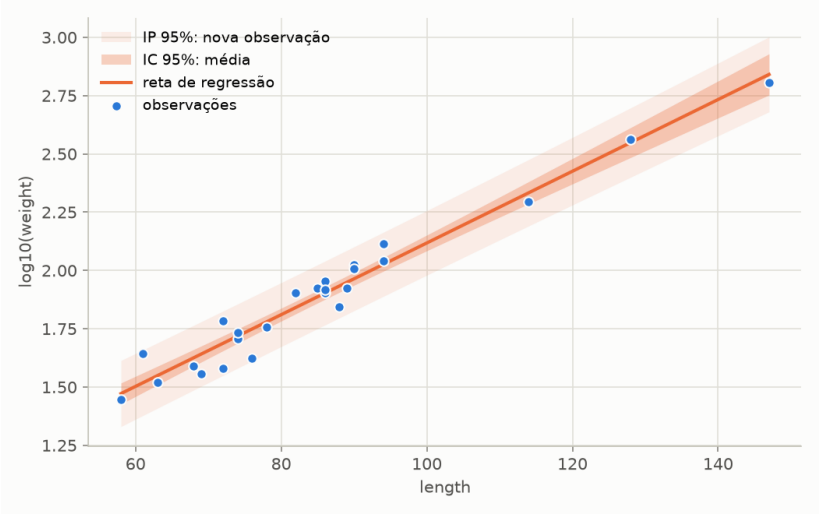


Figura XVII: Reta de regressão com intervalos de confiança e de predição de 95% (Alligators, dados transformados).

3. Análise dos resíduos

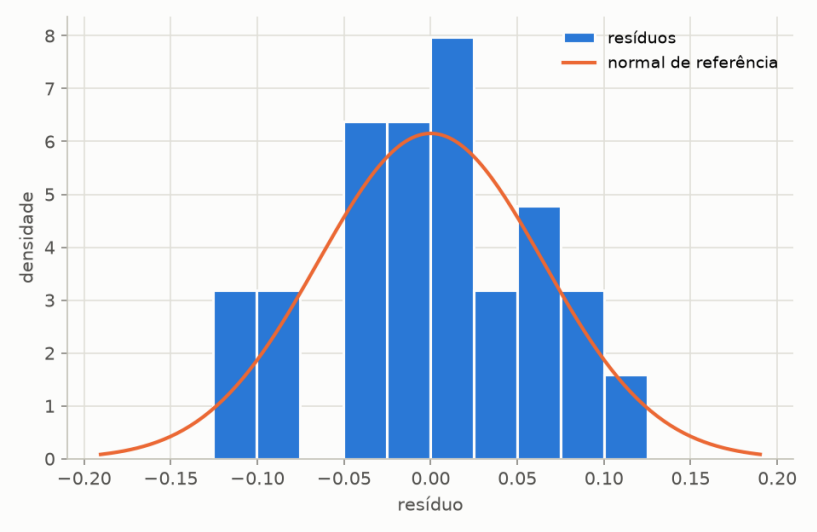


Figura XVIII: Histograma dos resíduos com a densidade normal de referência (Alligators, dados transformados).

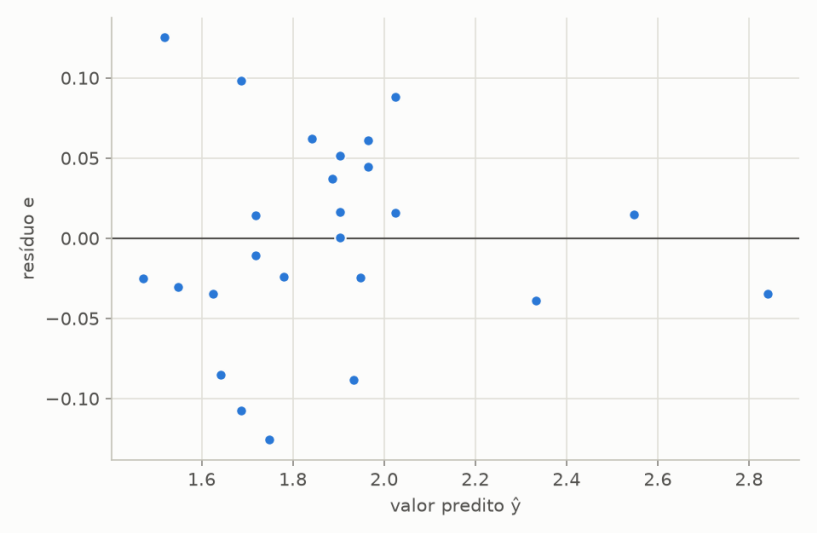


Figura XIX: Resíduos vs. valores preditos (Alligators, dados transformados).

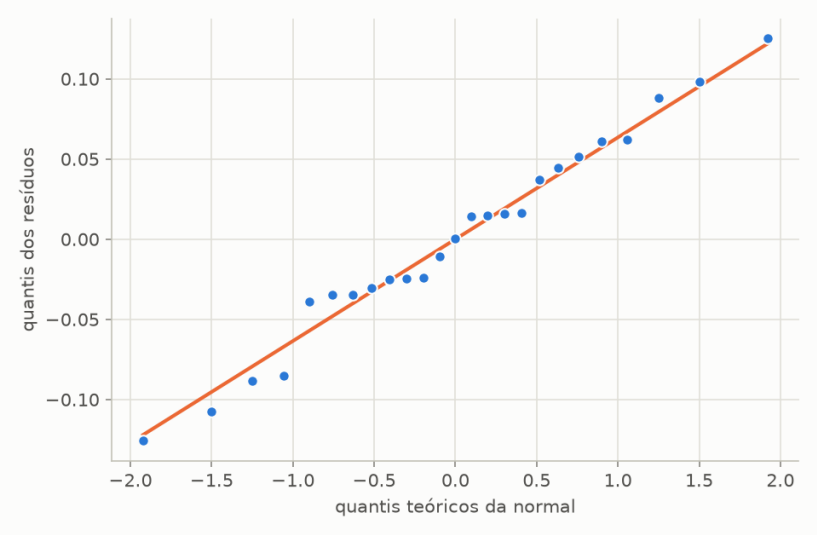


Figura XX: QQ-plot dos resíduos contra a distribuição normal (Alligators, dados transformados).

4. Premissas LINE

Linearidade (L) *Atendida.* O gráfico de resíduos vs. valores preditos passa a mostrar uma nuvem sem padrão em torno de zero, com resíduos entre cerca de $-0{,}13$ e $0{,}13$.

Independência (I) *Parece atendida.* Vale o mesmo motivo da análise original, já que a transformação não muda a forma como os jacarés foram amostrados.

Normalidade (N) *Atendida.* O histograma ficou próximo do formato de sino da normal de referência e no QQ-plot os pontos acompanham a reta de perto, inclusive nas pontas.

Variância igual (E) *Atendida.* Os resíduos não formam funil ao longo dos valores preditos, embora só 3 jacarés ocupem os maiores valores.

III. Dataset ConcPatog

O *dataset* ConcPatog traz as concentrações de dois protozoários em água de esgoto tratado, medidas em diferentes estações de tratamento, estágios e meses do ano. O interesse é verificar se é possível estimar, com razoável acurácia, a concentração do patógeno 2 (`CPatog2`, variável resposta Y) a partir da concentração do patógeno 1 (`CPatog1`, variável preditora X).

A. *Análise preliminar sobre os dados originais*

1. *Gráfico de dispersão*

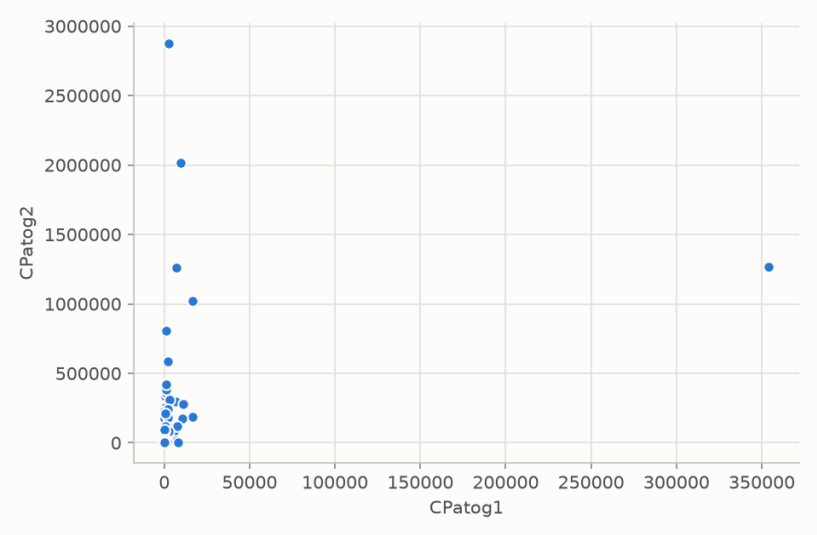


Figura XXI: Dispersão entre CPatog2 e CPatog1 (ConcPatog, dados originais).

No gráfico original não há indício visual de associação linear, porque quase todos os pontos ficam espremidos perto da origem, com 104 dos 105 valores de CPatog1 abaixo de 17 mil e 98 dos 105 valores de CPatog2 abaixo de 500 mil. Dentro desse aglomerado a dispersão de CPatog2 é muito grande, e alguns pontos extremos dominam o gráfico, como um único CPatog1 perto de 354 mil e quatro valores de CPatog2 acima de 1 milhão com CPatog1 baixo. As duas variáveis se estendem por várias ordens de grandeza, com CPatog1 indo de 0 a 354 mil (mediana 359) e CPatog2 de 4 a quase 3 milhões (mediana 13.900), o que comprime os pontos perto da origem e esconde qualquer tendência na escala original.

2. *Ajuste do modelo*

OLS Regression Results

Dep. Variable:	CPatog2	R-squared:	0.095
Model:	OLS	Adj. R-squared:	0.086
Method:	Least Squares	F-statistic:	10.81
		Prob (F-statistic):	0.00138
		Log-Likelihood:	-1497.3
No. Observations:	105	AIC:	2999.
Df Residuals:	103	BIC:	3004.
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	1.315e+05	3.76e+04	3.497	0.001	5.69e+04	2.06e+05
CPatog1	3.5583	1.082	3.288	0.001	1.412	5.705

Omnibus:	146.846	Durbin-Watson:	1.531
Prob(Omnibus):	0.000	Jarque-Bera (JB):	4365.918
Skew:	5.147	Prob(JB):	0.00
Kurtosis:	32.866	Cond. No.	3.51e+04

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 3.51e+04. This might indicate that there are
strong multicollinearity or other numerical problems.

Tabela VII: Resultados do ajuste por mínimos quadrados (ConcPatog, dados originais).

A reta explica menos de 10% da variação de CPatog2, com R^2 de 0,095 e R^2 ajustado de apenas 0,086 (Tabela VII), então o modelo não captura bem a variabilidade da resposta. A inclinação aparece como significativa ($p = 0{,}001$), mas esse valor depende das premissas LINE, que não valem aqui, e ela é muito influenciada pelo único ponto com CPatog1 perto de 354 mil, já que sem ele passaria de 3,6 para cerca de 43. A nota [2] dessa tabela fala em multicolinearidade, mas com uma só preditora ela não existe, e o número de condição alto vem apenas da escala de CPatog1, que chega a centenas de milhares. Na Figura XXII, o intervalo de predição chega a cerca de −630 mil para CPatog1 igual a 0, um valor que não faz sentido para uma concentração.

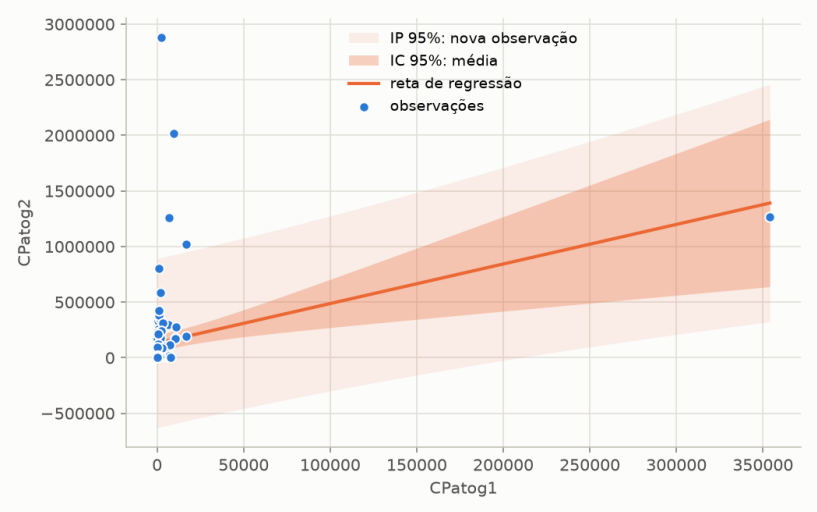


Figura XXII: Reta de regressão com intervalos de confiança e de predição de 95% (ConcPatog, dados originais).

3. Análise dos resíduos

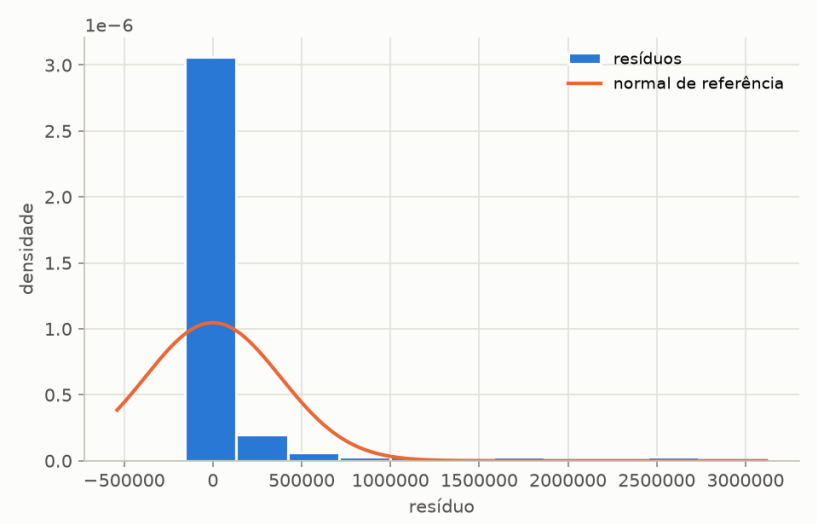


Figura XXIII: Histograma dos resíduos com a densidade normal de referência (ConcPatog, dados originais).

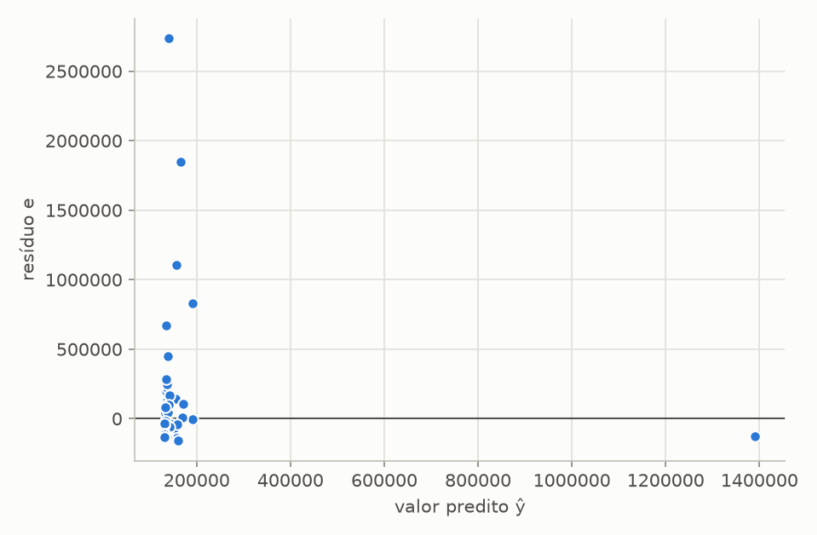


Figura XXIV: Resíduos vs. valores preditos (ConcPatog, dados originais).

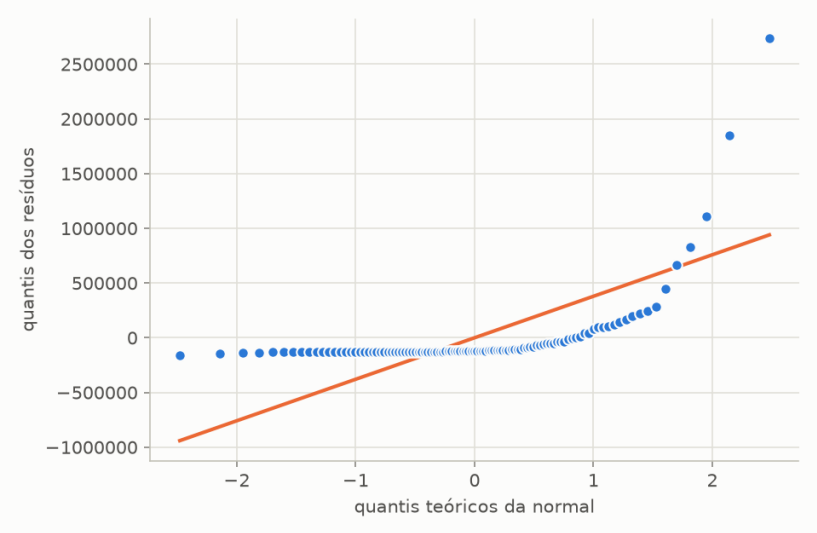


Figura XXV: QQ-plot dos resíduos contra a distribuição normal (ConcPatog, dados originais).

4. Premissas LINE

Linearidade (L) *Violada.* No gráfico de resíduos vs. valores preditos quase todos os pontos ficam empilhados numa faixa estreita de valores preditos, entre 130 mil e 200 mil, com resíduos de cerca de −160 mil a mais de 2,7 milhões. Além disso, 84 dos 105 resíduos são negativos, com mediana perto de −121 mil, então a reta passa acima da maioria dos pontos, puxada por poucos valores enormes.

Independência (I) *Questionável.* As 105 amostras vêm de 3 estações de tratamento acompanhadas nos 12 meses, com até uma amostra de cada estágio por estação e mês, e supomos que amostras da mesma estação e do mesmo mês tenham erros parecidos entre si.

Normalidade (N) *Violada.* O histograma é extremamente assimétrico à direita, com quase todos os resíduos numa única barra perto de zero e uma cauda longa, e no QQ-plot os pontos formam uma curva bem longe da reta.

Variância igual (E) *Parece violada.* Com os pontos empilhados numa faixa tão estreita de valores preditos não dá para ver um funil no gráfico, mas os resíduos das amostras com CPatog1 abaixo de 100 têm desvio padrão de cerca de 20 mil, contra cerca de 580 mil nas amostras com CPatog1 acima de 1.000, e supomos que a variância cresça junto com a concentração.

B. Exploração das transformações de escala

As nove dispersões do ConcPatog estão na Figura XXVI, e a Tabela VIII mostra o R^2 ajustado e o n de cada combinação, com a escolhida em negrito.

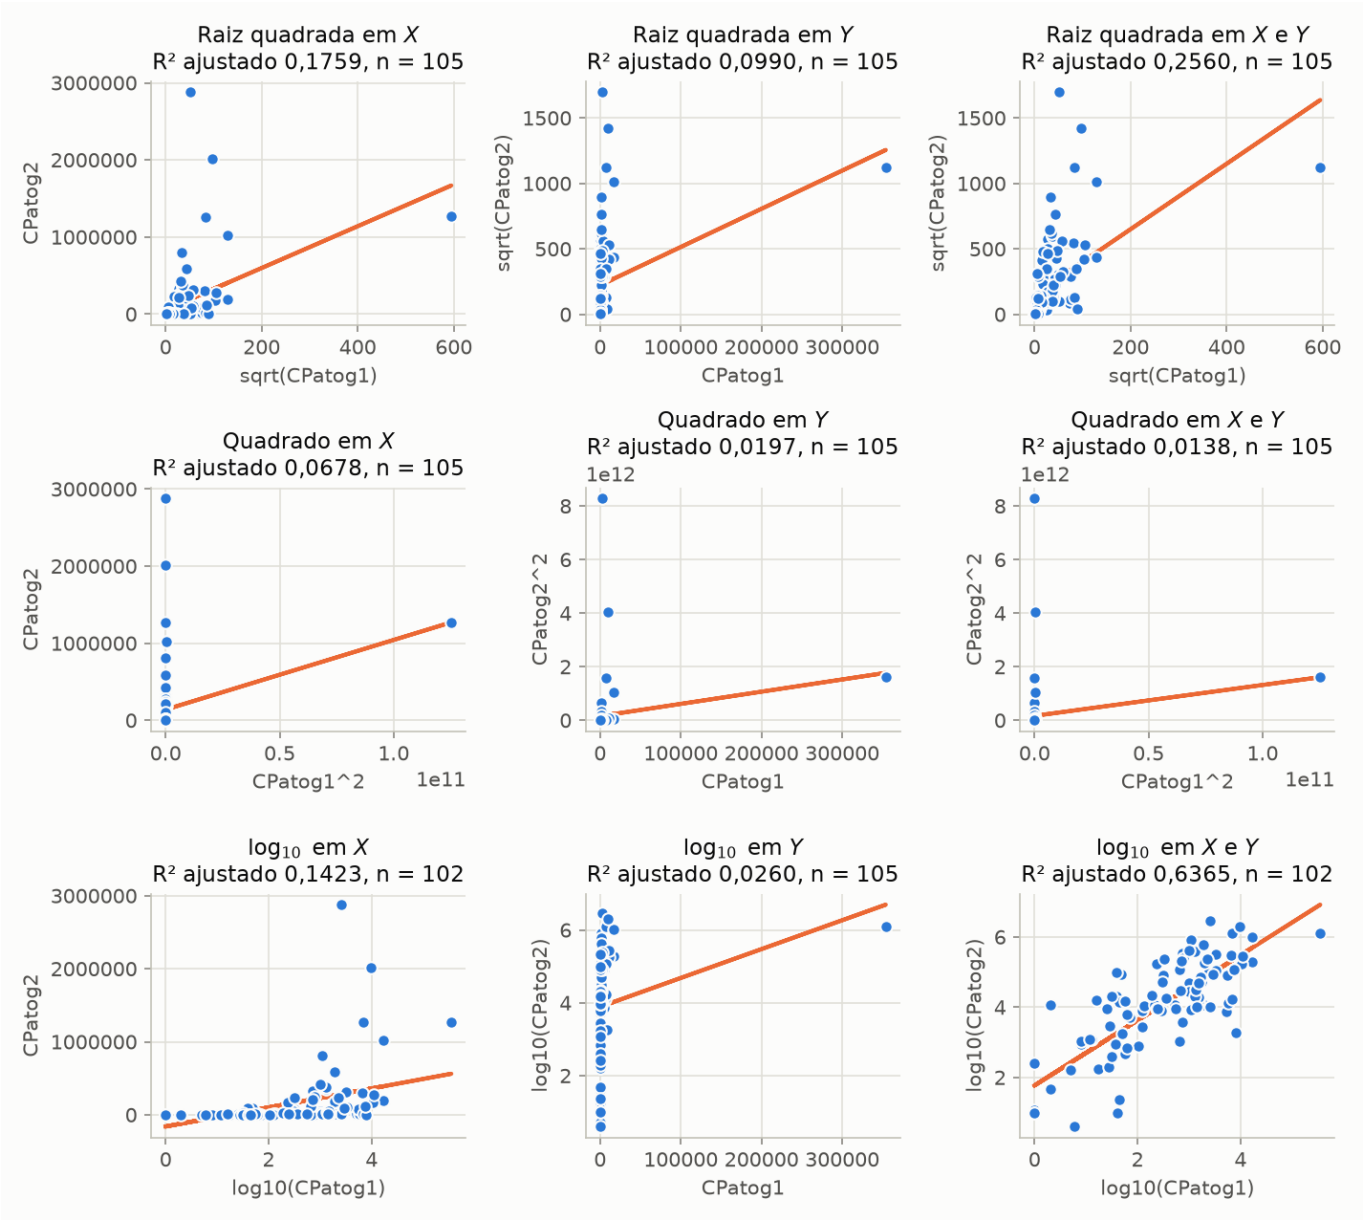


Figura XXVI: Dispersão e reta ajustada para as nove combinações de transformações (ConcPatog).

Transformação	Aplicada em	R^2 ajustado	n
Nenhuma	–	0,0862	105
Raiz quadrada	X	0,1759	105
Raiz quadrada	Y	0,0990	105
Raiz quadrada	X e Y	0,2560	105
Quadrado	X	0,0678	105
Quadrado	Y	0,0197	105
Quadrado	X e Y	0,0138	105
$\log_{10}$	X	0,1423	102
$\log_{10}$	Y	0,0260	105
$\log_{10}$	***X* e *Y***	**0,6365**	**102**

Tabela VIII: R^2 ajustado das combinações de transformações testadas no *dataset* ConcPatog.

Nas combinações com $\log_{10}$ em X, as 3 amostras com CPatog1 igual a 0, todas do estágio de reúso, precisaram ser removidas, porque o logaritmo de zero não existe, e por isso essas combinações têm $n = 102$. Preferimos remover essas linhas a somar uma constante antes do logaritmo, porque são só 3 de 105 amostras e o efeito de somar uma constante depende da unidade da variável. As combinações com quadrado e as que transformam só Y continuam com os pontos espremidos e dominados por poucos valores extremos. A raiz quadrada e o $\log_{10}$ só em X espalham melhor os valores de CPatog1, mas deixam CPatog2 concentrado perto de zero, e a raiz quadrada nas duas variáveis ajuda um pouco, embora ainda deixe a maioria dos pontos perto da origem. Só com o $\log_{10}$ em X e Y os pontos se espalham pelo gráfico e mostram uma associação linear positiva clara, com R^2 ajustado de 0,6365, muito acima do de qualquer outra combinação, o que combina com o fato de as duas variáveis se estenderem por várias ordens de grandeza.

C. Análise da combinação escolhida

Aqui a escolha foi o $\log_{10}$ nas duas variáveis, com $\log_{10}$(CPatog2) ajustado em função de $\log_{10}$(CPatog1) e sem as 3 amostras com CPatog1 igual a 0.

1. Gráfico de dispersão

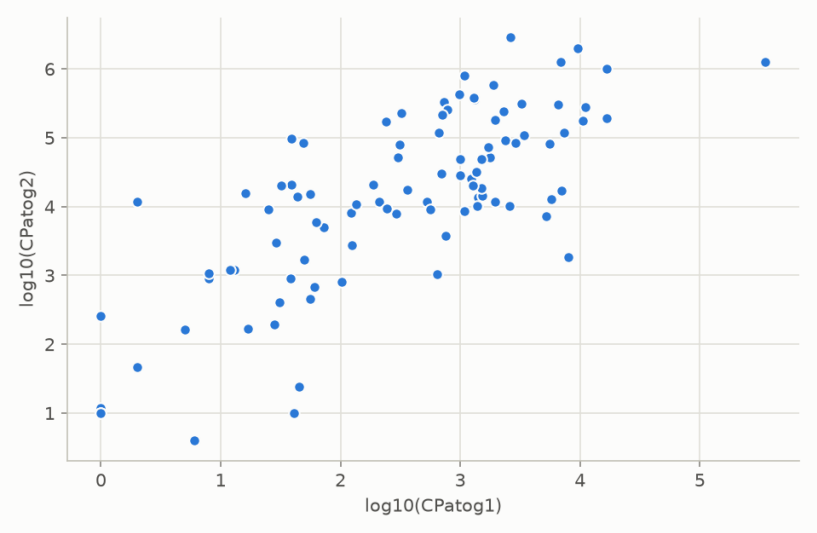


Figura XXVII: Dispersão entre $\log_{10}$(CPatog2) e $\log_{10}$(CPatog1) (ConcPatog, dados transformados).

Na escala logarítmica os pontos deixam de ficar espremidos perto da origem e se espalham por todo o gráfico, mostrando uma associação linear positiva, em que amostras com mais do patógeno 1 tendem a ter mais do patógeno 2. A dispersão em torno da tendência ainda é grande, já que para valores parecidos de CPatog1 o CPatog2 chega a variar cerca de 4 unidades de $\log_{10}$, um fator de 10 mil. O ponto com CPatog1 perto de 354 mil, que antes dominava o gráfico, continua sozinho na ponta direita, mas agora fica perto da tendência dos demais.

2. Ajuste do modelo

OLS Regression Results

Dep. Variable:	log10(CPatog2)	R-squared:	0.640
Model:	OLS	Adj. R-squared:	0.637
Method:	Least Squares	F-statistic:	177.9
		Prob (F-statistic):	6.36e-24
		Log-Likelihood:	-126.16
No. Observations:	102	AIC:	256.3
Df Residuals:	100	BIC:	261.6
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	1.7698	0.188	9.437	0.000	1.398	2.142
log10(CPatog1)	0.9277	0.070	13.337	0.000	0.790	1.066

Omnibus:	0.569	Durbin-Watson:	1.651
Prob(Omnibus):	0.752	Jarque-Bera (JB):	0.321
Skew:	-0.132	Prob(JB):	0.852
Kurtosis:	3.078	Cond. No.	6.75

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Tabela IX: Resultados do ajuste por mínimos quadrados (ConcPatog, dados transformados).

O ganho no R^2 ajustado é grande, de 0,086 para 0,637 (Tabela IX), e, com base nesse indicador, o modelo captura uma parte razoável da variabilidade de $\log_{10}$(CPatog2), mas 36% dela continua sem explicação. Esse valor também é de $\log_{10}$(CPatog2) e foi calculado sem as 3 amostras com CPatog1 igual a 0, então serve só de indicação na comparação com o modelo original. A inclinação de 0,93 indica que, quando CPatog1 é multiplicado por 10, o CPatog2 previsto é multiplicado por $10^{0,93} \approx 8{,}5$, uma relação quase proporcional entre os dois patógenos. Mesmo assim o modelo não permite estimar CPatog2 com razoável acurácia para uma amostra individual, porque o intervalo de predição de 95% é muito largo. Para CPatog1 igual a 1.000, por exemplo, o CPatog2 previsto é de cerca de 36 mil, mas o intervalo vai de cerca de 750 a 1,7 milhão, então o valor real pode ficar até umas 50 vezes acima ou abaixo do previsto. O modelo serve então para indicar a tendência e a ordem de grandeza do CPatog2 típico, já que para o mesmo CPatog1 de 1.000 o intervalo de confiança vai só de cerca de 23 mil a 55 mil. Supomos ainda que parte da associação venha do estágio de tratamento, que reduz a concentração dos dois patógenos ao mesmo tempo.

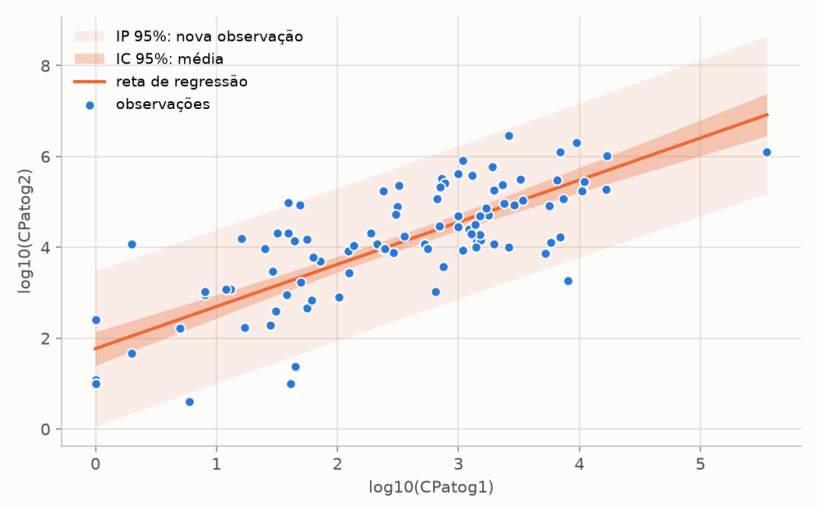


Figura XXVIII: Reta de regressão com intervalos de confiança e de predição de 95% (ConcPatog, dados transformados).

3. Análise dos resíduos

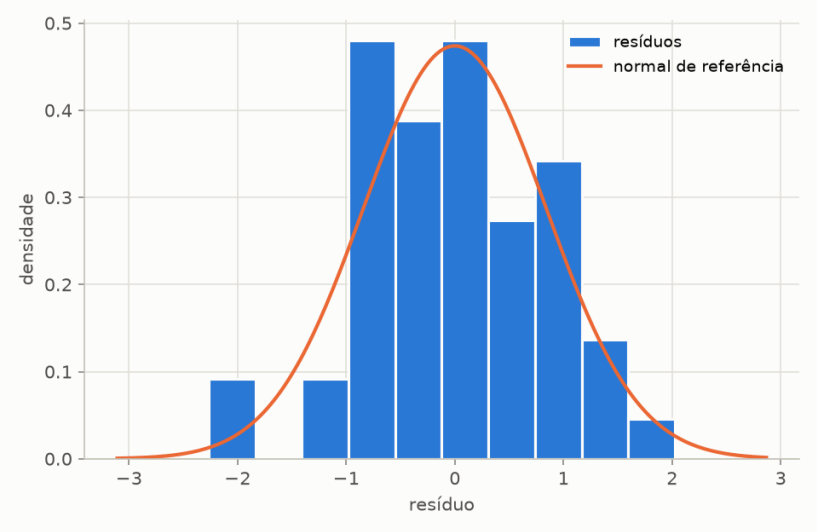


Figura XXIX: Histograma dos resíduos com a densidade normal de referência (ConcPatog, dados transformados).

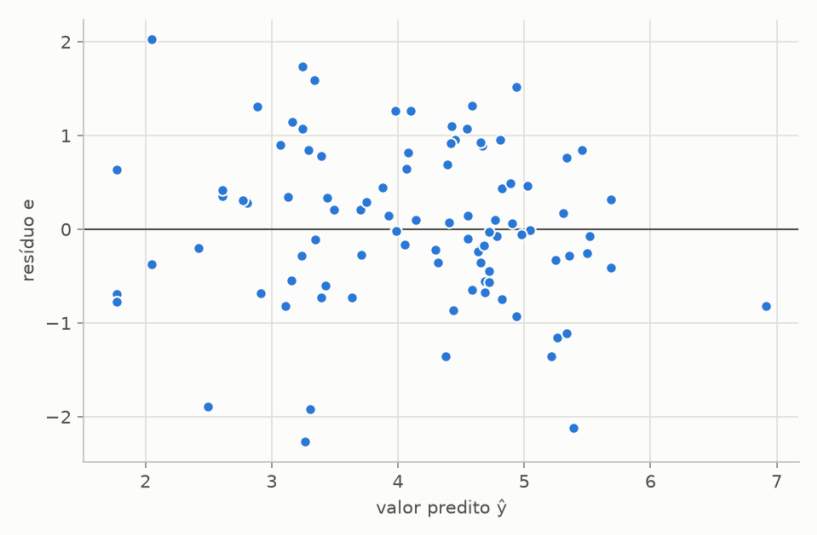


Figura XXX: Resíduos vs. valores preditos (ConcPatog, dados transformados).

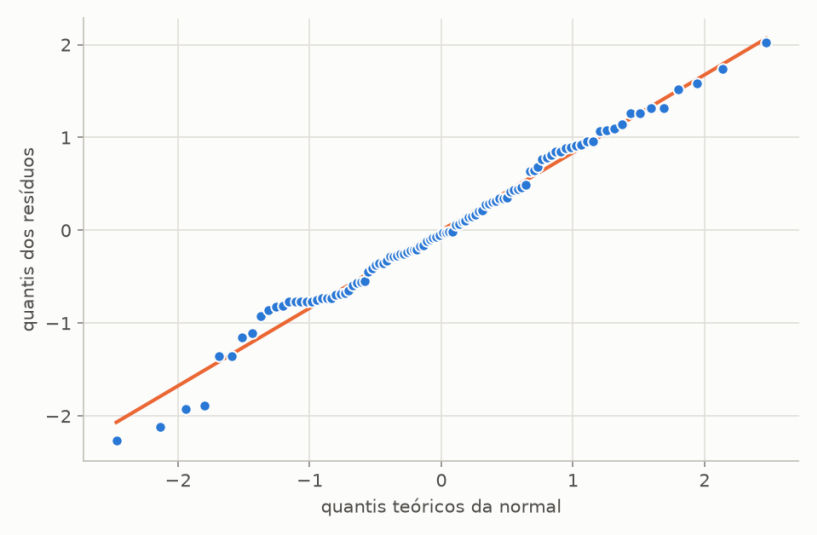


Figura XXXI: QQ-plot dos resíduos contra a distribuição normal (ConcPatog, dados transformados).

4. Premissas LINE

Linearidade (L) *Atendida.* Os resíduos em $\log_{10}$ se espalham ao acaso em torno de zero, entre cerca de $-2{,}3$ e $2{,}0$, sem nenhum padrão.

Independência (I) *Questionável.* A transformação não muda o fato de as amostras serem agrupadas por estação de tratamento, estágio e mês.

Normalidade (N) *Atendida.* O histograma fica perto da curva de referência e o QQ-plot quase todo em cima da reta, tirando um leve desvio na cauda inferior.

Variância igual (E) *Atendida.* A nuvem de resíduos tem mais ou menos a mesma largura ao longo dos valores preditos, sem formato de funil.

Voltando à pergunta que motiva o ConcPatog, como linearidade, normalidade e variância igual parecem atendidas na escala logarítmica, os intervalos da Figura XXVIII podem ser usados, com a ressalva de que a independência continua questionável. Eles mostram que o modelo indica bem a tendência e a ordem de grandeza do CPatog2 típico, mas não estima o CPatog2 de uma amostra individual com razoável acurácia, já que o intervalo de predição de 95% cobre mais de três ordens de grandeza.

Referências

[1] THE PENNSYLVANIA STATE UNIVERSITY. **STAT 501: Regression Methods**. University Park: Eberly College of Science. Disponível em: `https://online.stat.psu.edu/stat501/`. Acesso em: 11 out. 2026.